

TARTU ÜLIKOOL
Arvutiteaduse instituut
Infotehnoloogia mitteinformaatikule õppekava

Liis Lille

**Puuliikide tuvastamine Eesti metsades Sentinel-2
satelliidipiltide aegridade põhjal**

Magistritöö (15 EAP)

Juhendaja:

vanemteadur Mait Lang *PhD*

Tartu 2026

Puuliikide tuvastamine Eesti metsades Sentinel-2 satelliidipiltide aegridade põhjal

Lühikokkuvõte

Käesolevas magistritöös uuriti Lääne-Eesti alamregiooni näitel, kui täpselt on võimalik enamuspuuliiki (suurima tagavaraga puuliik) klassifitseerida ja puistute puuliigilist koosseisu (puuliikide osakaalud) prognoosida Sentinel-2 satelliidi aegridade ning kõrgus- ja mullastikuandmete põhjal. Andmestikud moodustati metsaregistri andmete põhjal selle alamregiooni kohta (9117 puhtpuistu eraldist ja 10 282 puht- ning segapuistuid sisaldavat eraldist). Enamuspuuliigi klassifitseerimise peamised mudelid treeniti puhtpuistute põhilandmestikul; laiendatud, ka segapuistuid sisaldavat andmestikku kasutati puistu puuliigilise koosseisu prognoosimiseks. Võrreldi Random Foresti ja XGBoosti algoritme neljaastmelise hierarhilise mudeliarhitektuuriga (liigirühmade kaupa järjestikku rakenduvad alamudelid), katsetati eri tunnuste valiku strateegiaid, hinnati kõrgus- ja mullastikuandmete mõju ning võrreldi mudelite tulemuslikkust puhtpuistute põhilandmestikul ja puht- ning segapuistuid sisaldaval laiendatud andmestikul. Parim mudel (XGBoost) saavutas testandmestikul enamuspuuliigi klassifitseerimise õigsuseks 0,870 ja Coheni kappaks 0,820, ületades Random Forestit kõigil mõõdikutel. Koostati ka pikslipõhine (10 m) enamuspuuliigi kaart Lääne-Eesti alamregiooni ulatuses. Valitud hierarhiline XGBoost saavutas Lääne-Eesti alamregiooni testandmestikul kõrge klassifitseerimistäpsuse, kuid tulemuste üldistatavus teistele piirkondadele vajab sõltumatut valideerimist.

Võtmesõnad:

Sentinel-2 aegread, enamuspuuliigi klassifitseerimine, Random Forest, XGBoost, kaugseire

CERCS:

P176 Tehisintellekt

B430 Metsakasvatus, metsandus, metsandustehnoloogia

T181 Kaugseire

Tree Species Mapping in Estonian Forests Using Sentinel-2 MSI Image Time Series

Abstract

This master's thesis investigated, using the Western Estonia subregion as a case study, how accurately the dominant tree species (the tree species with the highest growing stock volume) can be classified and the tree species composition of forest stands (species proportions) predicted using Sentinel-2 satellite time series together with height and soil data. The datasets were compiled from the Estonian Forest Register and included 9,117 pure-stand parcels and 10,282 parcels containing both pure and mixed stands. The main models for dominant tree species classification were trained using the core dataset of pure stands, while the extended dataset containing both pure and mixed stands was used to compare model performance and to predict tree species composition.

Random Forest and XGBoost algorithms were compared within a four-level hierarchical model architecture consisting of sequentially applied submodels for different species groups. Different feature selection strategies were tested, the effect of adding height and soil data was evaluated, and model performance was compared between the pure-stand core dataset and the extended dataset containing both pure and mixed stands. The best-performing model (XGBoost) achieved an overall accuracy of 0.870 and a Cohen's kappa of 0.820 on the test dataset, outperforming Random Forest across all evaluation metrics. A pixel-based (10 m) dominant tree species map was also produced for the Western Estonia subregion.

The selected hierarchical XGBoost model achieved high classification accuracy on the Western Estonia subregion test dataset, but the generalisability of the results to other regions requires independent validation.

Keywords:

Sentinel-2 time series, tree species classification, Random Forest, XGBoost, remote sensing

CERCS:

P176 Artificial intelligence

B430 Silviculture, forestry, forestry technology

T181 Remote sensing

Sisukord

1. Sissejuhatus.....	6
2. Teoreetiline taust ja varasemad uuringud	8
2.1 Puuliigiline koosseis ja referentsandmed.....	8
2.2 Sentinel-2 aegread ja puuliikide spektraalsed erinevused	9
2.3 Masinõppemeetodid puuliikide tuvastamisel.....	10
2.4 Mudeli täpsust mõjutavad tegurid.....	12
2.5 Varasemate uuringute süntees ja uurimislünk	12
3. Andmed ja metoodika	14
3.1 Uurimisala.....	14
3.2 Treeningandmestiku koostamine	15
3.2.1 Puhtpuistute põhiandmestik	15
3.2.2 Laiendatud andmestik	16
3.2.3 Lageraie eraldiste eemaldamine.....	17
3.3 Sisendtunnused	17
3.3.1 Sentinel-2 aegread.....	18
3.3.2 Kõrgus- ja mullastikuandmed	19
3.4 Andmete eeltöötlus ja ruumiline jaotus	20
3.5 Modelleerimine	21
3.5.1 Enamuspuuliigi klassifitseerimine	21
3.5.2 Puistu puuliigilise koosseisu prognoosimine	22
3.6 Tunnuste valik ja hierarhiline mudeliarhitektuur.....	23
3.7 Mudelite tulemuslikkuse hindamine	25
3.8 Pikslipõhise puuliigikaardi koostamine ja kontroll.....	27
3.9 Uurimuse töövoog.....	29
3.10 Tehisintellekti kasutus	31
4. Tulemused.....	32
4.1 Baasmudeli tulemused	32
4.2 Prognoosimiseks kasutatud tunnuste ja mudelikomponentide mõju	34
4.2.1 Kõrgus- ja mullastikutunnuste mõju.....	37
4.2.2 Informatiivsemad Sentinel-2 tunnused	38
4.3 Parim mudel.....	39

4.4 Tulemused puistu vanuse järgi.....	42
4.5 Segapuistute kaasamine ja puistu koosseisu prognoosimine	43
4.5.1 Klassifitseerimistulemused laiendatud andmestikul	43
4.5.2 Puuliikide osakaalude prognoosimine	43
4.6 Pikslipõhine puuliigikaart	45
5. Arutelu	47
5.1 Enamuspuuliigi klassifitseerimine	47
5.2 Sentinel-2 aegrea ja tunnuste valiku mõju	49
5.3 Kõrgus- ja mullastikuandmete ning mudeliarhitektuuri mõju	50
5.4 Segapuistud ja puistu puuliigilise koosseisu prognoosimine	51
5.5 Metoodilised piirangud ja tulemusi mõjutavad tegurid	53
5.6 Praktiline väärtus ja edasised uurimissuunad	55
6. Kokkuvõte.....	57
Summary	59
Viidatud kirjandus.....	61
Lisad.....	64
Lihtlitsents.....	73

1. Sissejuhatus

Metsad on Eesti üks olulisemaid loodusvarasid, pakkudes toorainet puidutööstusele, elupaiku paljudele liikidele ja mitmesuguseid ökosüsteemiteenuseid (Kliimaministeerium, 2026). Statistilise metsainventuuri andmetel katavad metsad 51,8% Eesti maismaast (Keskkonnaagentuur, 2024). Lisaks seovad metsad süsinikku ja aitavad leevendada kliimamuutusi (Shanin jt, 2014). 2023. aastal heaks kiidetud maakasutuse, maakasutuse muutuse ja metsanduse (LULUCF, *Land Use, Land-Use Change and Forestry*) määruse muudatuste eesmärk on suurendada Euroopa Liidu kasvuhoonegaaside netosidumist 2030. aastaks 310 miljoni CO₂-ekvivalenttonnini, mis on ligikaudu 15% praegusest suurem (European Parliament & Council of the European Union, 2023). LULUCF sektori eesmärkide täitmine suurendab vajadust ajakohase, usaldusväärse ja kogu riiki hõlmava metsainfo järele.

Traditsiooniliselt määratakse puistu liigiline koosseis metsainventuuri välitöödel. Need annavad üksikasjalikku teavet, kuid on suurel alal aja- ja töömahukad ning võivad raiete, kahjustuste ja loodusliku arengu tõttu kiiresti vananeda. Samuti ei ole kõik Eesti metsad kaetud inventeerimisandmetega. Kaugseire ei asenda välitöid ega kvaliteetseid referentsandmeid, kuid võimaldab metsainventuuri täiendada regulaarselt uueneva ja ruumiliselt ühtse teabega.

Sentinel-2 satelliitide korduvad multispektraalsed vaatlused võimaldavad kirjeldada puistute spektraalseid ja fenoloogilisi erinevusi kogu kasvuperioodi jooksul. Sentinel-2 aegridade ja masinõppemethodite abil on varasemates uuringutes saavutatud puuliikide klassifitseerimisel häid tulemusi (Grabska jt, 2019; Hemmerling jt, 2021). Eestis koostasid Lang jt (2018) Sentinel-2, Landsat-8 ja mullastikuandmete põhjal piirkondlikud puuliigimudelid. Käesolevas töös laiendatakse piirkondlikku lähenemist tihedama Sentinel-2 aegrea, kõrgusandmete, eri tunnuste valiku strateegiate, hierarhilise mudeliarhitektuuri ning Random Foresti ja XGBoosti võrdlusega.

Uurimus keskendub Lääne-Eesti alamregioonile (pindala 10 547 km²). Eraldi hinnatakse puhtpuistutel ja segapuistuid sisaldaval andmestikul õpetatud mudelite tulemuslikkust. Lisaks enamuspuliigi klassifitseerimisele uuritakse puuliikide osakaalude prognoosimist ning koostatakse parima mudeli põhjal pikslipõhine enamuspuliigikaart. Töö on seotud Keskkonnaagentuuri kaugseirepõhiste metsaandmete arendamisega.

Töö eesmärk

Magistritöö eesmärk on hinnata Sentinel-2 aegridade ning kõrgus- ja mullastikuandmete kasutamise võimalusi metsaeraldise enamuspuliigi klassifitseerimisel ja puliigilise koosseisu prognoosimisel Lääne-Eesti alamregiooni näitel. Selleks võrreldakse Random Foresti ja XGBoosti algoritme, võrreldakse mudelite tulemuslikkust puhtpuistute põhiaandmestikul ja puht- ning segapuistuid sisaldaval laiendatud andmestikul ning analüüsitakse tunnuste valiku ja hierarhilise mudeliarhitektuuri tulemuslikkust.

Uurimisküsimused

1. Kui täpselt võimaldavad Random Forest ja XGBoost Sentinel-2 aegridade ning kõrgus- ja mullastikuandmete põhjal klassifitseerida metsaeraldise enamuspuliiki ning kumb algoritm annab parema tulemuse?
2. Kuidas erineb enamuspuliigi klassifitseerimise tulemuslikkus puhtpuistute põhiaandmestikul ja puht- ning segapuistuid sisaldaval laiendatud andmestikul ning kui täpselt on võimalik prognoosida puistu puliigilist koosseisu?
3. Millised Sentinel-2 spektraalkanalid, vegetatsiooniindeksid ja ajavahemikud on puliikide eristamisel kõige informatiivsemad ning millist lisaväärtust annavad kõrgus- ja mullastikuandmed?
4. Milline tunnuste valiku strateegia ja mudeliarhitektuur (ühetasandiline või hierarhiline) annab parima klassifitseerimistulemuse?

Töö teoreetiline taust ja varasemad uuringud esitatakse peatükis 2. Peatükis 3 kirjeldatakse andmeid ja meetodikat, peatükis 4 tulemusi ning peatükis 5 nende tähendust ja uuringu piiranguid. Peamised järeldused võetakse kokku peatükis 6. Lisas 1 on esitatud varasemate satelliidipõhiste puliikide uuringute võrdlustabel, lisas 2 peamiste katsete ja hüperparameetrite otsingu kokkuvõte, lisas 3 töös kasutatud vegetatsiooniindeksite valemid.

Magistritöö koostamisel kasutati tehisintellekti Claude (Anthropic, 2026) teksti keelelisel ja sisulisel toimetamisel, lähtekoodi kirjutamisel ning peatükkide struktuuri korrigeerimisel. Kõik otsused mudelite ja meetodikate valiku osas ning järeldused on tehtud autori enda poolt.

2. Teoreetiline taust ja varasemad uuringud

Peatükis käsitletakse metsa puuliigilise koosseisu määramist metsas, Sentinel-2 aegridade kasutamist puuliikide eristamisel ning töös rakendatavaid masinõppemeetodeid. Lisaks antakse ülevaade mudelite täpsust mõjutavatest teguritest ja varasemate uuringute tulemustest, millest lähtudes kujundati käesoleva töö metoodika.

2.1 Puuliigiline koosseis ja referentsandmed

Puuliigiline koosseis kirjeldab puistus kasvavate puuliikide suhtelisi osakaale. Eesti metsakorralduses määratakse puistu enamuspuuliigiks selle rinde suurima tagavaraga puuliik (Metsa korraldamise juhend, 2024, § 11 lg 4). Koos puuliigilise koosseisuga hinnatakse metsainventuuri käigus muu hulgas puistu vanust, kõrgust, rinnaspindala, täiust, boniteeti ja kasvukohta (Metsa korraldamise juhend, 2024, § 5). Need andmed on aluseks metsamajandamise kavandamisele, metsavarude hindamisele, looduskaitsele ja riiklikule keskkonnaseirele.

Puuliigiline koosseis määratakse peamiselt metsakorraldaja välitööl silmamõõdulise takseerimise teel, mida vajaduse korral täpsustatakse mõõtmiste, loenduste või kaugseireandmetega (Metsa korraldamise juhend, 2024, § 5 lg 2). Metsaregistri andmed on masinõppemudelite jaoks väärtuslik referentsallikas, kuid nende kasutamisel tuleb arvestada inventeerimise aja ja tegeliku metsaseisundi võimaliku erinevusega. Raied, looduslik uuenemine ning tormi- ja putukakahjustused võivad põhjustada olukorra, kus registris kirjeldatud puistu ei vasta enam satelliidivaatluse ajal valitsenud olukorrale. Seetõttu sõltub kaugseirepõhise mudeli kvaliteet otseselt treeningandmete ajakohasusest ja usaldusväärsusest.

Puuliikide levikut ja puistute spektraalset signaali mõjutavad lisaks puistu koosseisule kasvukohatingimused ja puistu struktuur. Mullastik määrab kasvukohatüübi kaudu piirkonna niiskusraie ja toitainerikkuse, ning igal puuliigil on selle kasvukohatüüpide gradiendi ulatuses oma iseloomulik levikuala ehk sünökoloogiline areaal, kus ta looduslikult domineerib (Lõhmus, 2004). Mullakaart seab liikide levikule loogilisi piiranguid, sest mõned puuliigid ei kasva väheviljakatel või teatud tüüpi muldadel, samas kui teistel liikidel võib seal kohastumuse kaudu olla konkurentsieelis. Mulla boniteedist sõltub, kui kiiresti puu oma kõrguse saavutab, mistõttu kõrgusandmed annavad liigilise koosseisu kõrval täiendavat infot puuliigi kohta. Lang jt (2018) leidsid, et mullastikuandmed kuulusid Eesti puuliigikaardi koostamisel olulisemate

sisendtunnuste hulka. Seetõttu võivad kõrgus- ja mullastikuandmed täiendada satelliidipiltidelt saadavat spektraalset teavet.

2.2 Sentinel-2 aegread ja puuliikide spektraalsed erinevused

Metsade kaugseires kasutatakse aerofotosid, laserskaneerimist ning optilisi ja radarsatelliidiandmeid (White jt, 2016). Aerofotod võimaldavad kirjeldada puistute piire ja võrastiku struktuuri suure ruumilise detailsusega ning laserskaneerimine annab teavet metsa struktuuri ja kõrguse kohta. Optiliste satelliidiandmete eelis on suurte alade regulaarne vaatlemine ning taimkatte spektraalsete ja fenoloogiliste muutuste kirjeldamine. Käesolevas töös kasutatakse Sentinel-2 optilisi multispektraalseid andmeid.

Sentinel-2 koosneb kahest samaaegselt töötavast satelliidist. 2025. aasta jaanuaris asendas Sentinel-2C senise Sentinel-2A satelliidi (Copernicus Data Space Ecosystem, 2025), mistõttu käesoleva töö andmestik pärineb valdavalt Sentinel-2B ja Sentinel-2C satelliitidelt, üksikutel varasematel kuupäevadel ka Sentinel-2A-lt. Satelliidipaar võimaldab sama piirkonda vaadelda ligikaudu viiepäevase kordusintervalliga. Satelliitide Multispectral Instrument (MSI) mõõdab kirkust (ingl *radiance*) 13 spektraalkanalisis, mille ruumiline lahutusvõime on 10, 20 või 60 meetrit (European Space Agency, 2015). Metsade analüüsimisel kasutatakse peamiselt nähtava spektri, punaserva, lähiiinfrapuna ja lühilainelise infrapuna 10 ja 20 meetri lahutusega kanaleid (Grabska jt, 2019; Immitzer jt, 2019; Hemmerling jt, 2021).

Puuliikide eristamine põhineb võrastike spektraalsetel ja fenoloogilistel erinevustel. Lehtede pigmendisisaldus, ehitus ja veesisaldus ning võrastiku struktuur mõjutavad eri lainepikkustel mõõdetud peegeldust. Kasvuperioodi jooksul erinevad liigid lehtimise, sügisese värvimuutuse ja lehtede varisemise aja ning aktiivse kasvuperioodi pikkuse poolest. Aegread võimaldavad neid muutusi kirjeldada paremini kui üksikul kuupäeval tehtud vaatlus. Vaadates satelliitide ülelendude andmeid konkreetse puuliigi kohta näiteks terve aasta kohta joonistub välja selle puuliigi spektraalne signatuur kõikides kanalites. Kui liikide aegread on omavahel piisavalt erinevad on võimalik masinõppe abil liike tuvastada.

Grabska jt (2019, lk 10) uurisid üheksat puuliiki 305 km² suurusel segametsaalal Poola Karpaatides, kasutades 2018. aasta ühe-aastast Sentinel-2 aegrida ning 220 õpetus- ja valideerimispolügoni kokku 814,6 hektaril (jaotusega 70:30). Nad saavutasid ühe Sentinel-2 stseeniga (ühe ülesvõttega) õigsuse 84,9–87,4% ning viie hoolikalt valitud stseeni

kombineerimisel 92,4%. Kõigi stseenide kasutamine ei parandanud tulemust (92,12%), mis näitab, et vaatluste ajastus võib olla nende arvust olulisem. Hemmerling jt (2021) klassifitseerisid Saksamaal Brandenburgi liidumaa parasvöötme segametsades 17 puuliiki, kasutades Saksa riikliku metsainventuuri (2012) 387 775 üksikpuu asukoha põhjal moodustatud kaheaastast (2018–2019) Sentinel-2 aegrida, ning leidsid, et kaheaastane aegrida parandas klassifitseerimist võrreldes ühe-aastase aegreaga keskmiselt seitse protsendipunkti.

Puuliikide erinevused avalduvad sageli tugevamalt punaserva-, lähiinfrapuna- ja lühilainelise infrapuna kanalites. Punaserva kanalid on tundlikud klorofüllisisalduse suhtes, lähiinfrapuna kirjeldab lehtede ja võrastiku struktuuri ning lühilaineline infrapuna taimkatte veesisaldust. Kaha (2017, lk 19) uuringus vähendas lühilainelise infrapuna kanalite eemaldamine mudeli täpsust rohkem kui teiste kanalirühmade eemaldamine.

Spektraalkanalitest arvatud vegetatsiooniindeksid kirjeldavad koondatud kujul taimkatte aktiivsust, klorofüllisisaldust ja niiskust. Näiteks NDVI (*Normalized Difference Vegetation Index*) arvutatakse valemiga $NDVI = (NIR - Red) / (NIR + Red)$, kasutades otseselt samu lähiinfrapuna ja punase kanali väärtusi, mis on mudelis olemas ka eraldi tunnustena. Seega on indeksid ja neid moodustavad algsed kanalid omavahel tugevalt korreleeritud ning kannavad osaliselt kattuvat informatsiooni, mistõttu üksikute korreleeritud tunnuste olulisushinnanguid tuleb tõlgendada ettevaatlikult — mudel võib sama signaali olulisuse jaotada mitme tunnuse vahel juhuslikult. Seetõttu tuleb vegetatsiooniindeksite tegelikku panust hinnata koos tunnuste valiku tulemuste ja mudeli üldistusvõimega, mitte üksiku tunnuse olulisusskoori põhjal. Sellele vaatamata leidsid nii Immitzer jt (2019) kui ka Lechner jt (2022), et vegetatsiooniindeksite lisamine spektraalkanalitele parandas puuliikide klassifitseerimise tulemust, mistõttu pidasid nad indekseid kasulikuks täiendavaks tunnuserühmaks.

2.3 Masinõppemeetodid puuliikide tuvastamisel

Puuliigi prognoosimine kaugseireandmetest on masinõppe mõistes juhendatud õppe ülesanne: mudelile antakse treeningandmed, kus iga näite kohta on teada nii sisendtunnused kui ka tegelik väljundväärtus, ning mudel õpib nendevahelist seost, et teha prognoose uutel, märgendamata andmetel (Burkov, 2019). Puuliikide klassifitseerimisel on sisendtunnusteks satelliidi- ja lisaandmetest (nt Sentinel-2 multispektraalsed ajaread, kõrgus- ja mullastikuandmed) moodustatud tunnused ning väljundiks teadaolev puuliik või puuliigiline koosseis. Enamuspuuliigi määramine on klassifitseerimisülesanne, mille väljundiks on üks

puuliigiklass. Puistu puuliigilise koosseisu prognoosimisel hinnatakse seevastu mitme liigi osakaale ning ülesannet saab käsitleda regressioonina või tuletada osakaalud klassitõenäosustest.

Random Forest on ansambelõppe meetod, mis koosneb paljudest juhuslike õpetusobjektide ja tunnuste alamhulkade põhjal treenitud otsustuspuudest. Klass määratakse puude enamushääletuse või regressiooni tulemusena nende prognooside keskmise põhjal (Müller ja Guido, 2017, lk 83–84). Random Forest sobib hästi suure tunnuste arvuga andmestikele (Sügis jt, 2024, lk 107) ning võimaldab hinnata tunnuste olulisust (Müller ja Guido, 2017, lk 86). Nende omaduste tõttu on see Sentinel-2 andmetel põhinevates puuliigiuuringutes üks enim kasutatud algoritme (Lang jt, 2018; Grabska jt, 2019; Hemmerling jt, 2021). Lisas 1 on tabel, kus on võrreldud erinevates teadustöodes puuliikide tuvastamiseks kasutatud masinõppemeetodeid, saadud täpsusi ning kasutatud andmeid. Sellest võrdlusest nähtub, et Random Forest on valdkonnas selgelt enim kasutatud algoritm — kaheksa kümnest ülevaadatud uuringust kasutas seda põhimudelina.

XGBoost põhineb gradientvõimendamise (ingl *gradient boosting*) põhimõttel: otsustuspuud treenitakse järjestikku ning iga uus puu püüab vähendada eelmiste mudelite vigu. Selline lähenemine võib kirjeldada keerukaid tunnustevahelisi seoseid ja saavutada suure prognoositäpsuse, kuid on hüperparameetrite valiku ja üleõppimise suhtes tundlikum kui Random Forest (Müller ja Guido, 2017, lk 88–91). Seetõttu on Random Foresti ja XGBoosti võrdlus asjakohane, kui eesmärk on hinnata, kas järjestikune vigade parandamine annab suure ja heterogeense aegridade tunnustabeli korral eelise.

Samas ei kasutatud üheski ülevaadatud uuringus XGBoosti. Laiemas masinõppekirjanduses on leitud, et Random Forest ja gradientvõimendamisel põhinevad meetodid annavad tabelandmetel sageli võrreldavaid tulemusi, kuid gradientvõimendamine võib saavutada suurema täpsuse olukordades, kus Random Forest juba toimib hästi (Müller ja Guido, 2017, lk 91). Käesolevas töös kasutati tabelandmeid, kus tunnused olid agregeeritud eraldise tasemele. Sobiva võrdlusalgoritmi valiku otsuse toetamiseks viidi kasutataval andmestikul läbi ka esialgne automatiseeritud masinõppe (*AutoML*) analüüs FLAML-i teegi abil. Selle käigus võrreldi automaatselt nelja mudeliperekonda – LightGBM, XGBoost, Random Forest ja ExtraTrees – ning otsiti nende seast sobivaid mudeliseadistusi. XGBoost näitas selles esialgses võrdluses häid tulemusi, mistõttu valiti see Random Foresti kõrval käesoleva töö teiseks põhiliseks algoritmiks.

2.4 Mudeli täpsust mõjutavad tegurid

Mudeli tulemuslikkust mõjutab kogu andmetöötlusahel alates treeningandmete valikust kuni valideerimiseni. Aegunud või ebatäpsed metsakorraldusandmed kanduvad mudelisse vigaste klassimärgistena. Seetõttu tuleb treeningandmete koostamisel kontrollida inventeerimise aega ning eemaldada vahepeal raiutud või oluliselt muutunud puistud.

Oluline on ka puistu liigiline puhtus. Puhtpuistus pärineb suurem osa võrastiku spektraalsest signaalist ühelt liigilt, segapuistu keskmist peegeldust mõjutab aga mitme puuliigi erinev osakaal võras. Alusmetsa ja maapinna mõju peegeldusele on mõlemal juhul oluline. Puhtpuistud sobivad liigile iseloomulike signatuuride õppimiseks, kuid ainult nende põhjal treenitud mudel ei pruugi kirjeldada segapuistuid piisavalt hästi.

Spektraalset signaali mõjutavad lisaks puistu vanus, kõrgus, võrastiku katvus ja kasvukoht. Noortes või hõredates puistutes võivad maapind ja alustaimestik moodustada olulise osa mõõdetud peegeldusest, samas kui tihedama võrastikuga puistutes domineerib puude võrastiku signaal. Lang jt (2018) leidsid, et alla 20-aastaste puistute kaasamine vähendas klassifitseerimise täpsust.

Aegridade andmestikes võib tunnuste arv ulatuda sadadesse või tuhandetesse ning paljud tunnused on omavahel tugevalt seotud. Tunnuste valik võib vähendada arvutusmahtu ja üleõppimise riski, kuid liiga tugev vähendamine võib eemaldada haruldaste liikide eristamiseks vajalikku teavet. Lechner jt (2022) vähendasid tagasisuunalise valikuga tunnuste arvu 617-lt 50-le ilma mudeli täpsust vähendamata.

Mudeli hindamisel tuleb arvestada ruumilise autokorrelatsiooniga. Lähedikkude paiknevad puistud on sageli sarnaste kasvukoha- ja spektraalsete omadustega ning juhuslik objektipõhine andmejaotus võib anda üldistusvõimest liiga optimistliku hinnangu. Ruumiliselt eraldatud treening- ja testandmed võimaldavad paremini hinnata mudeli toimimist uutes asukohtades (Karasiak jt, 2022).

2.5 Varasemate uuringute süntees ja uurimislünk

Varasemates uuringutes on Sentinel-2 aegridade abil saavutatud puuliikide klassifitseerimisel häid tulemusi, kuid eri uuringute täpsused ei ole otseselt võrreldavad. Tulemusi mõjutavad

uurimisala (metsatüübid, puistute liigiline koosseis ja looduslik varieeruvus erinevad piirkonniti), puuliikide arv (rohkemate klasside eristamine on keerulisem), referentsandmete puhtus (segapuistute osakaal ja määramistäpsus) ning sisendtunnused (kasutatavad andmeallikad ja tunnuste arv).

Grabska jt (2019), Immitzer jt (2019) ja Hemmerling jt (2021) näitasid, et multitemporaalsed Sentinel-2 andmed võimaldavad kasutada puuliikide fenoloogilisi erinevusi ning et hoolikalt valitud vaatlused võivad olla informatiivsemad kui kõigi kuupäevade kasutamine. Lang jt (2018) saavutasid Eesti andmetel enamuspuliigi õigsuseks 75,5% ning näitasid mullastikuandmete kasulikkust. Klehr jt (2025) käsitlesid lisaks klassifitseerimisele puuliikide osakaalude regressioonipõhist prognoosimist.

Varasem kirjandus kinnitab Sentinel-2 aegridade, kasvukohatunnuste ja Random Foresti sobivust puuliikide hindamiseks. Osa uuringuid on kasutanud ka astmelist ehk hierarhilist lähenemist, mis lahutab keeruka mitmeklassilise ülesande järjestikusteks lihtsamateks alamülesanneteks — näiteks eristasid Immitzer jt (2019) esmalt okas- ja lehtpuude rühmad ning rakendasid seejärel iga rühma sees eraldi liikide klassifitseerimismudeleid.

Eestis on seni vähem uuritud mitmeastmelise hierarhilise klassifitseerimise, tunnuste valiku ja gradientvõimendamise kombineeritud kasutamist puuliikide eristamisel, samuti puht- ja segapuistute kaasamise mõju mudelite tulemustele. Seetõttu vajab Eesti tingimustes täiendavat uurimist, kui täpselt võimaldavad Sentinel-2 aegread koos Random Foresti ja XGBoostiga klassifitseerida metsaeraldise enamuspuliiki ning prognoosida puistu puuliigilist koosseisu. Nendest uurimisvajadustest lähtutakse käesoleva töö metoodika kujundamisel.

3. Andmed ja metoodika

Uuring hõlmas metsaeraldise enamuspuuliigi klassifitseerimist, puistu puuliigilise koosseisu prognoosimist ja pikslipõhise puuliigikaardi koostamist. Andmete allalaadimise, töötlemise, modelleerimise ja tulemuste visualiseerimise lähtekoodid kirjutati programmeerimiskeeles Python ning avaldati tööga kaasnevas GitHubi repositooriumis¹.

3.1 Uurimisala

Uurimisala määrati Lang jt (2018) Eesti alamregioonide põhjal. Selles jaotuses on Eesti ala jagatud kaheksaks piirkonnaks, mille sees on metsakasvutingimused suhteliselt sarnased. Piirkondlik lähenemine vähendab kasvukohtade erinevusest tulenevat varieeruvust ning piirab olukordi, kus mudel prognoosib liike piirkondades, kus nende esinemine on vähetõenäoline.



Joonis 3.1. Eesti metsanduslikud alamregioonid (Lang jt, 2018); punase raamiga on tähistatud Lääne-Eesti alamregioon.

Käesolevas töös uuriti Lääne-Eesti alamregiooni, mis hõlmab Mandri-Eesti lääneosas põhjalõunasuunalist riba laiusel ligikaudu 67 km ja pikkusega ligikaudu 159 km (joonis 3.1). Ühe alamregiooni kasutamine võimaldas hoida Sentinel Hub Statistical API² kaudu töödeldavate

¹ <https://github.com/LiisL/TreeSpecies>

² [Sentinel Hub Statistical API documentation](#)

andmete mahu teenuse kasutuspiiride sees (Sentinel Hub, n.d.-c) ning hinnata mudelite toimimist metsa kasvutingimusi arvestades võrdlemisi ühtlasel alal. Tulemuste üldistatavust teistele Eesti piirkondadele käesolevas töös ei hinnatud.

3.2 Treeningandmestiku koostamine

Treeningandmetena kasutati metsaregistri metsaeraldiste geomeetriaid ja metsakorralduslikke tunnuseid. Iga eraldise kohta kasutati enamuspuliiki, puliikide osakaale, inventeerimise kuupäeva, staatust (valiti registris aktiivsed eraldised) ja pindala. Andmestik hõlmas nii era- kui riigimetsi, omandivormi järgi eraldisi ei filtreeritud. Eri modelleerimisülesannete jaoks moodustati puhtpuistute põhiandmestik ning puht- ja segapuistuid sisaldav laiendatud andmestik.


3.2.1 Puhtpuistute põhiandmestik

Enamuspuliigi klassifitseerimise põhiandmestikku kaasati eraldised, mis vastasid järgmistele tingimustele:

1. inventeerimise kuupäev oli hilisem kui 1. jaanuar 2022;
2. eraldise staatus oli metsaregistris kehtiv;
3. eraldise pindala oli vähemalt üks hektar;
4. enamuspuliigi osakaal oli vähemalt 80%.

Suure enamuspuliigi osakaaluga eraldiste kasutamine vähendas segapuistutest tulenevat ebakindlust ja võimaldas mudelil õppida selgemaid liigispetsiifilisi signatuure. Pärast eespool loetletud tingimuste rakendamist jäi 9776 eraldist. Täiendav lageraiekontroll (ptk 3.2.3) eemaldas neist veel eraldisi, mille järel jäi lõplikku põhiandmestikku 9117 eraldist.

Klassifitseerimisel kasutati seitset klassi: männikud (MA), kaasikud (KS), kuusikud (KU), hall-lepikud (LV), sanglepikud (LM), haavikud (HB) ja muu (MUU). Klass MUU koondas väikese esindatusega puliigid, mille kohta ei olnud eraldi klassi moodustamiseks piisavalt eraldisi. Andmestiku klassijaotus on esitatud joonisel 3.2




Joonis 3.2. Puhtpuistute põhiandmestiku eraldiste jaotus enamuspüüliigi järgi treening-, valideerimis- ja testandmestikus.

Jooniselt on näha, milline oli iga püüliigi osakaal treening-, valideerimis- ja testandmestikus.

3.2.2 Laiendatud andmestik

Segapuistute mõju hindamiseks ja puistu püüliigilise koosseisu prognoosimiseks moodustati laiendatud andmestik. Sellesse kaasati lisaks puhtpuistutele eraldised, mille enamuspüüliigi osakaal oli 20–79%. Laiendatud andmestik sisaldas seega eraldisi, mille erinevate püüliikide osakaal oli 20–100%.

Andmestikku kuulus kokku 10282 eraldist, millest 7307 paigutati treening-, 1279 valideerimis- ja 1696 testandmestikku (joonis 3.3). Sama andmestikku kasutati kahel viisil. Klassifitseerimisülesandes oli sihttunnuseks eraldise enamuspüüliik. Koosseisu prognoosimisel olid sihttunnusteks seitsme püüliigiklassi osakaalud eraldises.



Joonis 3.3. Segapuistuid sisaldava laiendatud andmestiku eraldiste jaotus enamuspuuliigi järgi treening-, valideerimis- ja testandmestikus.

Jooniselt on näha, milline oli iga puuliigi osakaal treening-, valideerimis- ja testandmestikus.

3.2.3 Lageraie eraldiste eemaldamine

Metsaregistri inventeerimisandmete ja 2025. aasta satelliidivaatluste vahele jäi kuni kolmeaastane ajavahemik, mille jooksul võis puistu seisund muutuda. Treeningandmete ajakohasuse kontrollimiseks võrreldi eraldisi kahe Keskkonnaagentuuri koostatud lageraiealade vektorkihiga. Kihid hõlmasid ajavahemikke märtsist 2023 kuni veebruarini 2025 ning jaanuarist 2025 kuni veebruarini 2026.

Eraldis loeti võimaliku muutusega alaks, kui selle tsentroid paiknes lageraiepolügoonis. Sellised eraldised eemaldati andmestikust, sest lageraieala spektraalne signatuur ei kirjelda enam metsaregistris märgitud puuliiki. Andmebaasipäringu abil välistati laiendatud andmestikust ka eraldised, mille kohta oli kehtiv metsateatis. Puhtpuistute põhiandmestikust eemaldati lageraie- ja metsateatisekontrolli tulemusel kokku 659 eraldist (vt ptk 3.2.1).

3.3 Sisendtunnused

Mudelite sisendtunnused moodustati Sentinel-2 aegridadest, puistu kõrgust kirjeldavatest kõrgusandmetest ning kasvukohta kirjeldavatest mullastikuandmetest. Sentinel-2 andmed

kirjeldasid puistute spektraalset ja fenoloogilist arengut, kõrgusandmed puistu struktuuri ning mullastikuandmed kasvukohatingimusi.

3.3.1 Sentinel-2 aegread

Puistute spektraalse ja fenoloogilise arengu kirjeldamiseks kasutati Sentinel-2 Level-2A atmosfäärikorrektsooniga pinnapeegeldusandmeid. Aegread moodustati Sentinel Hub Statistical API abil (Sentinel Hub, n.d.-c). Teenus võimaldas arvutada statistilised tunnused otse metsaeraldiste polügoonidele, mistõttu ei olnud vaja kõiki satelliidistseene eraldi alla laadida ja töödelda.

Andmed hõlmasid ajavahemikku 11. jaanuarist kuni 18. oktoobrini 2025 ning jaotati 27 ajavahemikuks, millest igaüks hõlmas ligikaudu kümme päeva. Sama ligikaudu kümnepäevast ajavahemikku kasutasid ka Klehr jt (2025); Hemmerling jt (2021) kasutasid sarnast, kuid tihedamat viiepäevast intervalli. Iga ajavahemiku kohta arvutati eraldise pikslite keskmine ja mediaan. Kasutatud spektraalkanalid ja vegetatsiooniindeksid on esitatud tabelis 3.1. Üks ajavahemikest (11. jaanuar) oli kõigi eraldiste lõikes täielikult puuduvate väärtustega ega olnud seetõttu tunnustabelis kasutatav. Lõplikku mudelisse läksid ülejäänud 26 ajavahemiku kohta kümne spektraalkanalid ja nelja vegetatsiooniindeksi (NDVI, NDRE, NDMI, NBR) keskmised väärtused — kokku 364 Sentinel-2 aegrea tunnust. Koos kõrgus- (5 tunnust) ja mullastikutunnustega (357 one-hot-kodeeritud mullakoodi, vt ptk 3.3.2) hõlmas sisendtunnuste kogum 726 tunnust.

Tabel 3.1. Sentinel-2 aegride tunnused

Tunnuserühm	Tunnused	Eraldise statistikud
Nähtav spekter	B02, B03, B04	Keskmine ja mediaan
Punaserv	B05, B06, B07	Keskmine ja mediaan
Lähiinfrapuna	B08, B8A	Keskmine ja mediaan
Lühilaineline infrapuna	B11, B12	Keskmine ja mediaan
Vegetatsiooniindeksid	NDVI, NDRE, NDMI, NBR, EVI, CIRE (valemid vt Lisa 3)	Keskmine ja mediaan

Statistical API päringus kasutatud *evalscript* (Sentinel Hub, n.d.-a) — JavaScript-põhine skript, mis määrab, milliseid andmekanaleid ja töötusi API väljund sisaldab — küsis kümme spektraalkanalit B02–B12 ning *Scene Classification Layeri* (*SCL*) ja *dataMask*-kihi (andmemaski). Spektraalkanalid küsiti peegeldustegurina (ingl *reflectance*) ning nende põhjal arvutati kuus vegetatsiooniindeksit. *SCL* ja *dataMask* olid kvaliteedikihid, mida kasutati pikslite filtreerimiseks ning mida mudeli sisendtunnustena ei kasutatud.

Stseenitasandil määrati pilvisuse ülempiiriks 30%. Pikslitasandil kaasati *SCL*-klassid 4, 5 ja 6 ning rakendati *dataMask*-filtrit. Filtreerimine toimus enne eraldisepõhiste statistikute arvutamist.

Kuna päringus ei määratud eraldi mosaiikimisviisi, kasutati Statistical API vaikeväärtust *simple*. Mosaiikimine tähendab siin viisi, kuidas ajavahemiku sobivatest pikslivaatlustest moodustatakse üks pikslipõhine kiht. Ühe ajavahemiku piires moodustati sobivatest stseenidest pikslipõhine mosaiik ning iga piksli jaoks kasutati viimast kättesaadavat sobivat vaatlust. Seejärel arvutati valitud pikslitest eraldise keskmine ja mediaan.

Kui ajavahemikus ei olnud eraldise kohta sobivat vaatlust, jäeti väärtus puuduvaks. Aegrida ei silutud ega interpoleeritud. Kümnapäevane samm võimaldas kirjeldada kasvuperioodi ajalist muutust, hoides samal ajal tunnuste arvu ja puuduvate vaatluste osakaalu hallatavana.

3.3.2 Kõrgus- ja mullastikuandmed

Sentinel-2 aegridade tunnustele lisati kõrgus- ja mullastikuandmed, et hinnata puistu kõrguse ja kasvukohatingimusi kirjeldavate tunnuste olulisust enamuspuuliigi klassifitseerimisel ja puistu koosseisu prognoosimisel.

Puistute kõrgusandmed pärinesid Keskkonnaagentuuri koostatud kümnemeetrise ruumilise lahutusega rasterandmestikust (Keskkonnaagentuur, 2025), mis on kättesaadav ka metsaregistri kaudu. Iga eraldise kohta arvutati minimaalne, maksimaalne, keskmine ja mediaankõrgus ning kõrguse standardhälve. Keskmise ja mediaankõrguse põhjal oodati puistu arengufaasi ja üldise kõrguse kirjeldamist, standardhälbe põhjal aga puistu struktuurset mitmekesisust, mis võib viidata liigilise koosseisu või rindelisuse erinevustele.

Mullastikuandmed saadi Eesti mullastikukaardist (Maa-amet, 2001). Iga metsaeraldise kohta määrati pindalaliselt domineeriv mullatüüp. Kuna mullatüüp oli kategooriline tunnus, teisendati see mudeli eeltöötles indikaatortunnusteks, kasutades *one-hot*-kodeerimist.

3.4 Andmete eeltöötlus ja ruumiline jaotus

Sentinel Hub Statistical API väljund oli pikkformaadis andmestik, milles iga rida kirjeldas ühe eraldise üht ajavahemikku. Mudeldamiseks teisendati see laiformaadi tunnustabeliks. Igale eraldisele vastas üks rida, ning iga veerg tähistas kindla ajavahemiku ja tunnuse (nt spektraalkanal või vegetatsiooniindeks) keskmise kombinatsiooni — näiteks üks veerg sisaldas kindla spektraalkanali keskmist väärtust ühe kindla ajavahemiku kohta. Kõrgus- ja mullastikuandmed ühendati tunnustabeliga eraldise identifikaatori (id) alusel.

Puuduvad numbrilised väärtused asendati treeningandmestiku mediaaniga ning mullatüüp kodeeriti *one-hot*-meetodil. Eeltötluse parameetrid nagu imputeerimiseks kasutatud mediaanid ja kodeerimisel arvestatud mullatüübid, määrati üksnes treeningandmete põhjal ning rakendati muutmata kujul valideerimis- ja testandmetele. Numbrilisi tunnuseid ei standardiseeritud, sest Random Forest ja XGBoost põhinevad otsustuspuudel ja ei vaja seda (Müller ja Guido, 2017, lk 83).

Ruumilise autokorrelatsiooni mõju vähendamiseks jagati eraldised treening-, valideerimis- ja testandmestikuks GroupShuffleSplit-meetodiga. Ruumiline autokorrelatsioon tähendab, et geograafiliselt lähedastikku paiknevad metsaeraldised on sageli sarnaste omadustega, kuna neid mõjutavad muu hulgas samalaadsed mullastiku- ja kasvukohatingimused ning satelliidipildidel esinevad ruumiliselt seotud häiringud, näiteks hägu ja õhukesed kiudpilved. Kui eraldised jagataks andmestike vahel täiesti juhuslikult, võiks üks eraldis sattuda treeningandmestikku ja selle vahetu naaber testandmestikku. Sellisel juhul sisaldaks testandmestik treeningandmetega väga sarnast teavet, mistõttu võiks mudeli täpsus olla kunstlikult ülehinnatud ega peegeldaks selle tegelikku üldistusvõimet geograafiliselt uutel aladel (Karasiak jt, 2022).

Sellise andmelekke ohu vähendamiseks moodustati eraldistest enne andmete jagamist $5 \text{ km} \times 5 \text{ km}$ ruudustikul põhinevad rühmad. Kõik samasse ruutu kuulunud eraldised paigutati alati samasse andmejaotusse, mistõttu ei saanud ruumiliselt lähedastikku paiknevad ja tugevalt korreleeruvad eraldised sattuda näiteks treening- ja testandmestikku eri pooltele. Sama ruumilist jaotust kasutati kõigis omavahel võrreldavates katsetes. Lääne-Eesti alamregioonis moodustus sel viisil kokku 277 ruutu, millest 193 kuulus treening-, 42 valideerimis- ja 42 testandmestikku.

Treeningandmeid kasutati mudelite õpetamiseks ning valideerimisandmeid mudeliversioonide, tunnuste ja hüperparameetrite võrdlemiseks. Testandmeid kasutati lõppmudelite üldistusvõime hindamiseks.

Erandiks oli uuriv analüüs, mida kasutati 18 autori enda poolt koostatud liigisignatuuri tunnuse kujundamiseks. Liikide spektraalse eristatavuse ja kõrguserinevuste kirjeldamiseks kasutati selles etapis treening-, valideerimis- ja testandmete ühendatud valimit. Analüüs ei hõlmanud mudeli treenimist ega täpsuse arvutamist, kuid analüüsi tulemused mõjutasid lõplike tunnuste koostamist. Seetõttu ei saa käsitsi koostatud tunnustega mudeli testtulemust käsitleda täielikult sõltumatu hinnanguna. Seda piirangut käsitletakse peatükis 5.5.

3.5 Modelleerimine

Uuringus lahendati kaks juhendatud masinõppe ülesannet:

1. metsaeraldise enamuspuuliigi klassifitseerimine;
2. seitsme puuliigiklassi osakaalude prognoosimine.

Mõlema ülesande puhul võrreldi Random Foresti ja XGBoosti.

3.5.1 Enamuspuuliigi klassifitseerimine

Enamuspuuliigi klassifitseerimisel oli sihttunnuseks üks seitsmest puuliigiklassist. Random Forest oli mudeli arendamise põhialgoritm, millega hinnati tunnuste valiku, kõrgus- ja mullastikuandmete, klasside tasakaalustamise, hüperparameetrite ning mudeliarhitektuuri mõju. XGBoost lisati võrdlusalgoritmiks, et hinnata gradientvõimendamise sobivust samale tunnustabelile ja mudeliarhitektuurile.

Andmestiku klassijaotus oli ebaühtlane. Männi- ja kaseeraldised moodustasid kokku üle 70% põhiaandmestikust, samal ajal kui haava osakaal oli 3,3% ja klassi MUU osakaal vaid 0,2%. Sellise klasside tasakaalustamatuse korral võib mudel eelistada sagedamini esindatud klasse ning saavutada kõrge õigsuse isegi, kui haruldasemaid klasse ei tuvastata hästi. Vastukaaluks võib klasside tasakaalustamine omakorda vähendada sagedamate klasside täpsust, mistõttu sobiv tasakaalupunkt sõltub sellest, kui kulukad on vead harvamate ja sagedamate klasside puhul rakenduse kontekstis.

Sagedasemate klasside domineerimise vähendamiseks kasutati Random Foresti treenimisel Scikit-learn'i teegi parameetrit `class_weight="balanced"`. Selle meetodi korral määratakse klasside kaalud pöördvõrdeliselt nende esinemissagedusega treeningandmestikus. Seetõttu saavad väiksema esindatusega klasside objektid mudeli õppimisel suurema kaalu kui sagedamini esinevate klasside objektid. Näidete kaale võetakse arvesse otsustuspuude hargnemiskriteeriumi arvutamisel — see on algoritmi sisseehtatud käitumine, mitte eraldi

valitav seadistus —, mistõttu mõjutavad haruldasemad klassid puude struktuuri rohkem kui kaalumata treenimise korral.

Valitud katsetes rakendati lisaks haruldasemate klasside ülevalimit (ingl *oversampling*), et suurendada nende esindatust treeningandmestikus: eraldised valiti asendamisega juhuslikult uuesti valimisse (ingl *random oversampling with replacement*) kuni sihttasemeni — hall lepp 2000, kuusk 1600 ning haab ja sanglepp 1200 eraldist vastavas hierarhia liigitasandi astmes, klass MUU 500 eraldist hierarhia esimeses astmes. Nii klassikaale kui ka ülevalimit rakendati üksnes treeningandmetele, et valideerimis- ja testandmestiku algne klassijaotus säiliks ning mudeli hindamistulemused peegeldaksid tegelikku andmejaotust.

Random Foresti lähtekonfiguratsioonis kasutati 400 otsustuspuud, minimaalset lehesuurust 2, minimaalset haru tekkimiseks vajalikku vaatluste arvu 2, hargnemisel kaalutavate tunnuste arvuna kõigi tunnuste arvu ruutjuurt (*max_features="sqrt"*) ning tasakaalustatud klassikaale. Puude sügavust ei piiratud, mis on Random Foresti puhul tavapärane valik, kuna üksikute sügavate puude ülesobitamist tasandab puude ansamblikeskmistamine (vt ptk 2.3), mitte iga üksiku puu enda piiramine. See kombinatsioon (väike minimaalne lehesuurus, piiramata sügavus) võib põhimõtteliselt siiski soodustada ülesobitamist, kuid hüperparameetrite võrguotsingu tulemused (lisa 2.2) näitasid, et lähtekonfiguratsioon jäi valideerimisandmestikul parima leitud konfiguratsiooni lähedale (Macro F1 0,654 vs 0,657). XGBoosti lähtekonfiguratsioonis kasutati 400 puud, maksimaalset puusügavust 6 ja õpisammu 0,1. Mõlema algoritmi alternatiivseid hüperparameetreid võrreldi valideerimisandmestikul võrguotsinguga (ingl *grid search*). Katsetatud konfiguratsioonid ja nende valideerimistulemused on esitatud lisa 2.

Random Foresti ja XGBoosti võrreldi esmalt puhtpuistute põhiandmestikul. Mudelite tulemuslikkust võrreldi ka puht- ning segapuistuid sisaldaval laiendatud andmestikul.

3.5.2 Puistu puuliigilise koosseisu prognoosimine

Puistu puuliigilise koosseisu prognoosimiseks kasutati laiendatud andmestikku. Mudelite sihtväärtusteks olid metsaregistris esitatud puuliikide protsentuaalsed osakaalud. Iga eraldise kohta oli registris kirjeldatud kuni viis puuliiki koos nende osakaaludega, kuid eri eraldiste puhul olid need liigid ja nende arv erinevad. Et kõigil eraldistel oleks samad, fikseeritud sihttunnused, koondati need väärtused seitsmeks püsivaks sihttunnuseks — üks iga töös kasutatud puuliigiklassi (kuus põhiliiki ja klass MUU) kohta —, kus eraldisel mitte esinenud liigi osakaaluks määrati null.

Enne mudelite õppimist normeeriti tegelikud osakaalud iga eraldise kohta summeeruma 100%-ni. Random Forest võimaldas mitmeväljundilist regressiooni ühe mudeliga, mis prognoosis korraga kõigi seitsme liigi osakaalu. XGBoostil puudus kasutatud teostuses sisseehitatud mitmeväljundilise regressiooni tugi. Seetõttu kasutati MultiOutputRegressor-ümbrist, mille abil treeniti iga liigi osakaalu jaoks eraldi XGBoost-regressioonimudel.

Järeltöötlustes asendati negatiivsed prognoosid nulliga ning iga eraldise prognoositud osakaalud normeeriti summeeruma 100%-ni.

Random Foresti puhul kasutati 400 puud, minimaalset lehesuurust 2 ja piiranguta sügavust. XGBoosti puhul kasutati 400 puud, maksimaalset sügavust 6 ja õpisammu 0,1.

3.6 Tunnuste valik ja hierarhiline mudeliarhitektuur

Mudelite arendamisel hinnati sisendandmete, tunnuste valiku, klasside tasakaalustamise, hüperparameetrite ja mudeliarhitektuuri mõju. Tunnuste komplekti, klasside tasakaalustamise, hüperparameetrite, arhitektuuri ja algoritmi mõju hinnati kontrollitud komponentide eemaldamise uuringus, kus kõik mudelid treeniti treeningandmetel ja neid hinnati valideerimisandmestikul. Igas võrdlusetapis muudeti üht kuuest eelnimetatud komponendist ning ülejäänud seaded hoiti võimalikult muutumatuna. Esmalt koostati kõiki Sentinel-2 aegrea tunnuseid kasutav baasmudel. Seejärel võrreldi kõrgus- ja mullastikuandmete lisamist, erinevaid tunnuste valiku strateegiaid, ühetasandilist ja hierarhilist arhitektuuri ning Random Foresti ja XGBoosti.

Tunnuste esituse osas võrreldi kolme lähenemist. Esimeses kasutati täielikku tunnuste kogumit, mis hõlmas kõiki kümnapäevaseid Sentinel-2 spektraalkanalite ja vegetatsiooniindeksite aegridu ning kõrgus- ja mullastikutunnuseid.

Teises lähenemises vähendati tunnuste arvu automaatselt. Treeningandmetel õpetatud Random Foresti ebapuhtuse (Gini indeksi) vähenemisel põhineva tunnuse olulisuse järgi järjestati kõik tunnused. See mõõdik näitab, kui palju tunnuse kasutamine hargnemiskriteeriumina vähendas keskmiselt otsustuspuude sõlmede klassisegunemist kõigi puude ja hargnemiste lõikes. Nende väärtuste alusel valiti tunnustest 100 või 50 kõige olulisemat. Neid tunnustekomplekte tähistati vastavalt Top-100 ja Top-50.

Kolmandas lähenemises kasutati 18 käsitsi koostatud liigisignatuuri tunnust kahel viisil: kontrollitud komponentide eemaldamise uuringus (ptk 4.2, tabel 4.3) hinnati neid eraldiseisva tunnustekomplektina, lõplikus konfiguratsioonis aga lisati need täielikule tunnuste kogumile

selle täienduseks. Need kombineerisid kindlate puuliikide eristamiseks informatiivseks hinnatud spektraalkanaleid ja vegetatsiooniindekseid valitud ajavahemikel. Näiteks sügisene sanglepa signatuuritunnus LM_autumn_index arvutati kanalite NDRE, NDVI, B8 ja B7 keskmisena 28. septembri vaatlusel. Tunnused koostati liikide aastaste spektraalsignatuuride visualiseerimise, üks-ülejäänute-vastu (ingl *one-vs-rest*) eristatavuse, liigipaaride standardiseeritud keskmiste erinevuse (Coheni d tüüpi mõõdik, ingl *Cohen's-d-type measure*) väärtuste ja kõrguserinevuste analüüsi põhjal. Mõõdik arvutati kahe liigi tunnuse keskmiste vahe ja ühendatud standardhälbe suhtena, kus ühendatud standardhälve oli kahe liigi standardhälvete ruutude keskmise ruutjuur — see on lihtsustatud, gruppide valimimahtu mitteamestav variant klassikalisest Coheni d-st, mis sobis siin uurivaks (eksploraatiivseks) tunnuste kujundamiseks. Tavapärase tõlgenduse kohaselt loetakse d väärtust alates 0,2-st väikeseks, alates 0,5-st keskmiseks ja alates 0,8-st suureks efekti suuruseks (Cohen, 1988).

Ühetasandilise seitsmeklassilise mudeli kõrval katsetati neljast järjestikku rakendatavast alammodellist koosnevat hierarhilist arhitektuuri:

1. esimene aste eristas okaspuid, lehtpuid ja klassi MUU;
2. okaspuude alammodell eristas kuusikuid ja männikuid;
3. lehtpuude esimene alammodell eristas halli leppa ülejäänud lehtpuudest;
4. lehtpuude teine alammodell eristas haavikuid, kaasikuid ja sanglepikuid.

Alammodellid treeniti vastava liigirühma treeningobjektidel. Mudeli rakendamisel suunati eraldi järgmise astmesse eelmise alammodelli prognoosi, mitte tegeliku klassi järgi. Nii hõlmas mudeli lõplik hinnang ka varasemates astmetes tehtud vigade edasikandumist. Klasside tasakaalustamine tehti eraldi iga alammodelli treeningandmetel.

Katsete põhietapid olid spektraalse baasmudeli koostamine, kõrgus- ja mullastikutunnuste mõju hindamine, tunnuste valik, klasside tasakaalustamise ja hüperparameetrite võrdlus, hierarhilise arhitektuuri katsetamine ning Random Foresti ja XGBoosti võrdlus. Seejärel võrreldi mudelite tulemuslikkust puhtpuistute põhiandmestikul ja puht- ning segapuistuid sisaldaval laiendatud andmestikul ning koostati puistu koosseisu regressioonimudelid. Peamiste katsete kokkuvõtte ja hüperparameetrite otsingu tulemused on esitatud lisas 2.

3.7 Mudelite tulemuslikkuse hindamine

Klassifitseerimismudeleid hinnati õigsuse (ingl *Accuracy*), tasakaalustatud täpsuse (ingl *Balanced Accuracy*), täpsuse (ingl *Precision*), saagise (ingl *Recall*), makro- ja kaalutud F1-skoori ning Coheni kappa abil. Klassidevaheliste eksimuste analüüsimiseks kasutati veamaatrikseid.

Õigsus näitab kõigi õigesti klassifitseeritud objektide osakaalu kogu andmestikust. Tasakaalustatud täpsus on iga klassi saagise keskmine, mis annab ebaühtlase klassijaotuse korral õiglasema hinnangu kui õigsus, kuna ei lase suurte klasside hea tulemus varjata väikeste klasside nõrka tulemust (Sügis jt, 2024). Õigsuse, täpsuse ja saagise kolmik vastab kaugseirepõhises liigikaardistuses väljakujunenud terminoloogiale (ingl *overall accuracy*, *user's accuracy*, *producer's accuracy*), mida kasutavad ka Grabska jt (2019) ja teised käesolevas töös viidatud uuringud.

$$\text{Õigsus} = \frac{\text{õigesti klassifitseeritud objektide arv}}{\text{objektide koguarv}} \quad (1)$$

Täpsus näitab, kui suur osa vaadeldavas klassi prognoositud objektidest kuulus sinna tegelikult:

$$\text{Täpsus}_i = \frac{TP_i}{TP_i + VP_i} \quad (2)$$

Saagis näitab, kui suur osa tegelikult klassi kuuluvatest objektidest õigesti tuvastati:

$$\text{Saagis}_i = \frac{TP_i}{TP_i + VN_i} \quad (3)$$

kus TP, VP ja VN tähistavad vastavalt tõsiposiitivsete, valepositiivsete ja valenegatiivsete näidete arvu (Sügis jt, 2024). Klassi i F1-skoor arvutati täpsuse ja saagise harmoonilise keskmisena:

$$F1_i = 2 \times \frac{\text{Täpsus}_i \times \text{Saagis}_i}{\text{Täpsus}_i + \text{Saagis}_i} \quad (4)$$

Klasside tasakaalustamatuse tõttu kasutati kontrollitud komponentide eemaldamise uuringus (ptk 4.2) makro-F1-skoori peamise tasakaalutundliku võrdlusmõõdikuna, kuna see annab kõigile klassidele võrdse kaalu ning ei lase suure esindatusega klassidel varjata väiksemate klasside nõrku tulemusi (Sügis jt, 2024). Lõpliku mudeli valikul ei kasutatud siiski üht ainsat mõõdikut, vaid arvestati lisaks õigsust, Coheni kappat ja klassipõhiseid F1-skoore (vt ptk 4.3):

$$Macro\ F1 = \frac{1}{C} \sum_{i=1}^C F1_i, \quad (5)$$

kus C on klasside arv. Kaalutud F1-skoor (ingl weighted F1) on defineeritud järgmiselt:

$$Weighted\ F1 = \sum_{i=1}^C \frac{n_i}{N} F1_i, \quad (6)$$

kus N on näidete koguarv ja n_i klassi i tegelike näidete arv. Kaalutud F1-skoor oleks samuti klasse arvestanud, kuid nende esinemissageduse järgi, mistõttu oleksid sagedasemad klassid (männikud, kaasikud) endiselt domineerinud — täpselt see probleem, mida makro-F1 valikuga vältida taheti, kuna harvema esindatusega klasside (nt haavik) tulemuslikkus oli töö jaoks sisuliselt oluline sõltumata nende väiksest osakaalust.

Klass MUU sisaldas testandmestikus ainult üht eraldist, mistõttu ei olnud selle klassi tulemust võimalik usaldusväärselt hinnata. Seetõttu arvutati makro-F1 ja tasakaalustatud täpsus nii kõigi seitsme klassi kui ka kuue põhipuuliigi kohta, jättes teisel juhul klassi MUU arvestusest välja.

Coheni kappa mõõtis prognoositud ja tegelike klasside kokkulangevust, arvestades ka juhuslikult oodatavat kokkulangevust (Cohen, 1960). Veamaatriksite abil analüüsiti, milliste liikide vahel esines enim süsteemseid eksimusi.

Random Foresti ja XGBoosti lõppmodelite prognooside erinevust hinnati McNemari paaristestiga (McNemar, 1947), kasutades samade testeraldiste paarisennustusi. Mõõdikute ebakindluse hindamiseks arvutati testandmestikust asendamisega moodustatud 5000 *bootstrap*-taasvalimi põhjal 95%-lised usaldusvahemikud.

Lõppmodelite täpsust hinnati eraldi ka alla 20-aastastes ja vähemalt 20-aastastes puistutes, et analüüsida puistu arengustaadiumi seost klassifitseerimistulemusega. Vale ja õige klassifikatsiooniga eraldiste kirjeldavate tunnuste (nt kõrgus) erinevust hinnati Mann-Whitney U testiga, mis ei eelda tunnuste normaaljaotust.

Puistu koosseisu prognoosimist hinnati iga liigi kohta determinatsioonikordaja R^2 , keskmise absoluutvea (MAE) ja ruutkeskmise vea (RMSE) abil (valemid 7–9):

$$R^2 = 1 - \frac{\sum_{j=1}^n (y_j - \hat{y}_j)^2}{\sum_{j=1}^n (y_j - \bar{y})^2}, \quad (7)$$

$$MAE = \frac{1}{n} \sum_{j=1}^n |y_j - \hat{y}_j|, \quad (8)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_j)^2}, \quad (9)$$

kus y_j on liigi tegelik osakaal eraldises j , $\hat{y}_j$ sama eraldise prognoositud osakaal, $\bar{y}$ tegelike osakaalude keskmine ja n testandmestiku eraldiste arv. Lisaks arvutati kõigi liikide eespool kirjeldatud MAE väärtuste keskmisena üks liikideülene koondnäitaja. Prognoositud koosseisust tuletatud enamuspuuliiki hinnati samade klassifitseerimismõõdikutega nagu otsest klassifitseerimismudelit.

Tunnuste mõju analüüsimiseks kasutati mudelipõhiseid tunnuste olulisuse hinnanguid. Kuna hierarhiline lahendus koosnes neljast eraldi õpetatud alammudelist, hinnati tunnuste olulisust mudeliastmete kaupa.

3.8 Pikslipõhise puuliigikaardi koostamine ja kontroll

Eraldisepõhiste klassifitseerimismodelite rakendatavuse näitlikustamiseks koostati Lääne-Eesti alamregiooni kohta 10×10 meetri ruumilise lahutusega piksline enamuspuuliigi kaart. Kaart koostati parima XGBoosti mudeli põhjal.

Kaardi tegemiseks laaditi Sentinel-2 Level-2A andmed alla Sentinel Hub Process API³ abil (Sentinel Hub, n.d.-b). Statistical API sobib statistikute arvutamiseks etteantud polügoonidele, kuid ei olnud otstarbekas üksikpikslite töötlemiseks. Process API päringutes kasutati Sentinel-2 kanalite, vegetatsiooniindeksite ja kvaliteedimaski moodustamiseks sama üldist *evalscript*'i loogikat nagu eraldisepõhise andmestiku koostamisel (vt ptk 3.3.1).

³ [Sentinel Hub Processing API documentation](#)

Kaardistamiseks koostatud piksliandmestik hõlmas 26 kümnepäevast ajaakent 2025. aastast (2025-01-31 kuni 2025-10-18). Sama ajavahemik ja sama arv ajaaknaid jäid alles ka eraldisepõhises tunnustabelis pärast tühjade veergude eemaldamist, mistõttu mudeli õpetamisel ja kaardistamisel kasutatud tunnuste ajaline tugi kattus.

Pikslitasandi tunnused moodustati tunnuserühmade kaupa erinevalt. Sentinel-2 spektraalkanalite ja vegetatsiooniindeksite korral kasutati iga piksli konkreetse ajaakna väärtust otse mudeli sisendina. Eraldisepõhise mudeli õpetamisel kirjeldasid vastavad tunnused eraldise pikslite keskmist või mediaani, kuid kaardistamisel üksikpiksli väärtust. Seega erines spektraaltunnuste ruumiline tugi (ingl *spatial support*) ehk ruumiline ulatus, mille põhjal üks tunnuseväärtus arvutati mudeli õpetamisel ja kaardistamisel.

Kõrgustunnuste moodustamisel kasutati ligikaudu ühe hektari suurust liikuvat ruumilist akent, mis vastas treeningandmestikku kaasatud väikseima eraldise pindalale, et hoida piksli- ja eraldisepõhiste kõrgustunnuste ruumiline tugi võimalikult sarnasena. Väiksem aken (nt 3×3 pikslit ehk 30×30 m) oleks selle erinevuse hoopis suurendanud, kuna oleks jäänud tunduvalt väiksemaks kui treeningandmestikus kasutatud eraldiste pindala. Iga piksli ümbruse kohta arvutati kõrguse keskmine, mediaan, standardhälve, miinimum ja maksimum. Nii ei taandunud kõrguse standardhälve nulliks ega miinimum ja maksimum üheks piksli väärtuseks.

Mullastikutunnuseks kasutati kaardistamisel piksli asukoha mullakoodi. Eraldisepõhises treeningandmestikus kirjeldas sama tunnus eraldise pindalaliselt domineerivat mullatüüpi. Seetõttu erines ka mullastikutunnuse ruumiline tähendus õpetus- ja kaardistamisandmestikus.

Pikslipõhiste tunnuste jaotuslikku vastavust eraldisepõhiste õpetustunnustele eraldi statistiliselt ei kontrollitud. Erinevast ruumilisest toest tulenevat võimalikku mõju käsitletakse peatükis 5.5.

Mudelite prognoosid piirati üle-eestilise metsamaski abil metsaks määratud pikslitele (Keskkonnaagentuur, 2026). Igale kehtivale metsapikslile määrati üks seitsmest puuliigiklassist. Hierarhilise mudeli korral rakendati pikslitele samu järjestikuseid alamudeleid ja suunamisreegleid nagu eraldisepõhisel klassifitseerimisel.

Kaardistusvoo tehniliseks kontrollimiseks võrreldi pikslipõhiseid prognoose metsaregistri eraldiste andmetega. Iga kaardiga kattuva eraldise piires loendati kategoorilise tsonaalstatistika abil eri puuliigiklassidesse prognoositud pikslid. Eraldise kaardipõhiseks enamuspuuliigiks määrati klass, mille pikslid olid eraldise piires arvuliselt ülekaalus. Kontroll piirdus

enamuspuuliigi (üksiku klassi) võrdlusega; piksliaotusest tuletatud koosseisuvektorit metsaregistri tegelike osakaaludega eraldi ei võrreldud.

Võrdlusest jäeti välja eraldised, mille piires ei olnud ühtegi metsamaski läbinud pikslit. Koondtulemuste arvutamisel kasutati ainult eraldisi, mille piires oli vähemalt viis kehtivat pikslit.

Tehniliseks kontrolliks kasutati kahte metsaregistri väljavõtet. Puhtpuistute põhiandmestiku korral võrreldi kaardipõhist enamuspuuliiki eraldise registrisse salvestatud enamuspuuliigiga. Laiendatud andmestiku korral kasutati võrdlusliigina eraldise suurima osakaaluga puuliiki. Suurima osakaaluga liik langes registri enamuspuuliigi tunnusega kokku 98%-l eraldistest, kus mõlemad väärtused olid määratud.


Kaardi ja eraldiste võrdlus ei olnud sõltumatu täpsushinnang, sest võrdluses sisaldasid ka mudelite treening- ja valideerimisandmestikku kuulunud eraldised. Lisaks vähendas eraldise pikslite enamushääletus (see tähendab, et eraldise kaardipõhine liik määrati pikslite hulgas enim esinenud klassi järgi) üksikute valesti klassifitseeritud pikslite mõju lõpptulemusele, mistõttu võis eraldisepõhine võrdlus jätta pikslitasandi tegelikest vigadest parema mulje, kui need tegelikult olid. Seetõttu kasutati võrdlust kaardistusvoo tehnilise toimimise, mitte sõltumatu kaarditäpsuse hindamiseks.

3.9 Uurimuse töövoog

Uurimuse üldine töövoog on esitatud joonisel 3.4. Esmalt valiti metsaregistrist sobivad eraldised ning kontrolliti nende ajakohasust. Seejärel moodustati ruumiliselt eraldatud treening-, valideerimis- ja testandmestikud ning lisati Sentinel-2 aegridadest, kõrgusandmestikust ja mullastikukaardist arvatud tunnused.

Puhtpuistute põhiandmestikku kasutati enamuspuuliigi klassifitseerimismudelite arendamiseks ning Random Foresti ja XGBoosti võrdlemiseks. Laiendatud andmestikku kasutati mudelite tulemuslikkuse võrdlemiseks puht- ning segapuistuid sisaldaval andmestikul ja puistu puuliigilise koosseisu prognoosimiseks. Mudelite arendamisel võrreldi tunnuste valiku, klasside tasakaalustamise, hüperparameetrite ja hierarhilise arhitektuuri mõju.

Lõppmudelite tulemuslikkust hinnati ruumiliselt eraldatud testandmestikul. Lisaks rakendati parimat hierarhilist klassifitseerimismudelit piksli tasandil ning koostati Lääne-Eesti alamregiooni puuliigikaart, misjärel kontrolliti kaardistusvoo tehnilist vastavust metsaregistri eraldiste andmetele.



Joonis 3.4. Uurimuse töövoog.

3.10 Tehisintellekti kasutus

Magistritöö valmimisel kasutati tehisintellekti (Claude, Anthropic, 2026) kahel eesmärgil. Esiteks kasutati seda tarkvaraarenduse abivahendina uurimuses kasutatud Pythoni koodibaasi kirjutamisel ja varasemate kirjutatud lähtekoodide korrigeerimisel – sealhulgas andmete allalaadimise skriptid, tunnuste moodustamise ja mudelite treenimise katsed (ptk 3.5–3.7) ning pikslipõhise puuliigikaardi koostamise ja kontrollimise skriptid (ptk 3.8). Iga katse eesmärk, hüpotees, meetodivalik ja tulemuste tõlgendus oli autori otsustada; tehisintellekti panus piirdus koodi kirjutamise, korrigeerimise ja dokumenteerimisega vastavalt autori püstitatud ülesannetele, mille alusel autor tegi järgmised metoodilised otsused.

Teiseks kasutati tehisintellekti töö teksti keelelisel ja struktuursel toimetamisel ning töö sisu kontrollimisel. Töö sisu kontrollimiseks paluti tehisintellektil leida ebakõlasid erinevate peatükkide vahel. Kõik tehisintellekti loodud lähtekoodid vaatas autor läbi ning kontrollis nende sisulist õigsust lähteandmete ja katsetulemuste alusel enne töösse lisamist.

4. Tulemused

4.1 Baasmudeli tulemused

Enne hierarhilise arhitektuuri, liigisignatuuri tunnuste ja lageraie eraldiste eemaldamise väljatöötamist koostati lihtne baasmudel (EXP000), mille tulemuste põhjal otsustati, milliseid täiustusi töö käigus katsetada. Baasmudel oli üheastmeline (mittehierarhiline) klassikaaludega ("*class_weight=balanced*") Random Forest mudel, mis kasutas kõigi Sentinel-2 ajaakende keskmist ja mediaani (peatükis 3.3.1 kirjeldatud lõplike mudelite ajaakende keskmisest laiemat tunnuste komplekti) ning kõrguse- ja mullastikutunnuseid. Baasmudeli tulemused testandmestikul on esitatud tabelis 4.1.

Baasmudelis ei rakendatud veel peatükis 3.2.3 kirjeldatud lageraie eraldiste eemaldamist ega peatükis 3.6 kirjeldatud liigisignatuuri tunnuseid. Seetõttu ei ole baasmudeli ja peatükis 4.3 esitatud lõplike mudelite tulemused otseselt võrreldavad: baasmudeli testandmestik sisaldas 1613 eraldist, samas kui lõplike mudelite testandmestik sisaldas pärast lageraiega kattuvate eraldiste eemaldamist 1510 eraldist. Baasmudeli tulemus näitab töö lähtepunkti, mitte hierarhilise arhitektuuri või muude hilisemate täiustuste eraldi mõju.

Tabel 4.1. Baasmudeli (EXP000) tulemused testandmestikul.

Mõõdik	Baasmudel
Õigsus	0,65
Tasakaalustatud täpsus	0,45
Makro-F1	0,46
Coheni kappa	0,53


Klassipõhised tulemused on esitatud tabelis 4.2. Kõige täpsemalt tuvastati männikud (F1 0,80) ja kaasikud (F1 0,68). Kõige halvemini tuvastati haavikud (F1 0,34) ja sanglepikud (F1 0,44): mõlema klassi saagis jäi väikeseks (vastavalt 0,24 ja 0,31), see tähendab, et suur osa nende liikide tegelikest eraldistest klassifitseeriti mõnda teise klassi. Klassi MUU tulemust ei olnud ainsa testeraldise tõttu võimalik usaldusväärselt hinnata: see üks eraldis klassifitseeriti valesti, mistõttu klassi F1-skoor jäi nulli.

Tabel 4.2. Baasmudeli klassipõhised tulemused testandmestikul.

Puuliik	Täpsus	Saagis	F1
Männikud (MA)	0,86	0,74	0,80
Kaasikud (KS)	0,65	0,71	0,68
Kuusikud (KU)	0,44	0,46	0,45
Hall-lepikud (LV)	0,41	0,68	0,51
Sanglepikud (LM)	0,76	0,31	0,44
Haavikud (HB)	0,56	0,24	0,34
Muu (MUU)	0,00	0,00	0,00

Veamaatriksist joonisel 4.1 nähtub, et baasmudeli suurimaks nõrkuseks oli kaasikute klassi laialdane segiajamine teiste liikidega mõlemas suunas. Kokku 70 tegelikult kaasikute eraldist klassifitseeriti hall-lepikuks ja 42 kuusikuks. Vastupidises suunas klassifitseeriti kaasikuks 45 hall-lepiku, 37 kuusiku ja 34 sanglepiku eraldist. Männikud eristusid teistest klassidest kõige selgemalt (õigesti tuvastati 408 eraldist 548-st ehk 74%), kuid ka männikute eraldistest klassifitseeriti 67 kaasikuks ja 56 kuusikuks. Haavik ja sanglepik jäid kõige raskemini tuvastatavaks: enamik nende eraldistest klassifitseeriti valesti kaasikuks või hall-lepikuks.

Kuusikute suhteliselt nõrka tulemust (täpsus 0,44, saagis 0,46, F1 0,45; valemid 2–4) selgitab osalt klassi väiksem esindatus puhtpuistute põhiandmestikus: treeningandmestikus oli kuuseeraldisi 596, männieraldisi aga 2387 ehk ligi neli korda rohkem, kuigi kuusikute ja männikute osakaal Lääne-Eesti metsamaastikul on tegelikkuses võrreldav. Väiksem esindatus tuleneb ilmselt sellest, et vähem kuuseeraldisi vastas puhtpuistu puhtuskriteeriumile. Hierarhilise mudeli (tabel 4.7) märgatavalt parem tulemus kuuse klassil (F1 0,73) näitab, et liik oli kasutatud tunnuste põhjal eristatav; kas paranemine tulenes peamiselt klasside tasakaalustamatuse leevendumisest, baasmudeli lihtsamast arhitektuurist või mõlemast korraga, ei ole eraldi katsetega võimalik lahutada.



Joonis 4.1. Baasmudeli (EXP000) veamaatriks testandmestikul.

Baasmudeli järel tehti veel täiendav andmete puhastamine, eemaldati lageraietega eraldised, katsetati erinevaid hüperparameetreid, mudeleid ja tunnuste mõju. Olulisemate eksperimentide lähtekood on GitHubi repositooriumis.

4.2 Prognoosimiseks kasutatud tunnuste ja mudelikomponentide mõju

Kontrollitud komponentide eemaldamise uuringu tulemused on esitatud tabelis 4.3.

Kontrollitud võrdluses saavutas üksnes Sentinel-2 tunnuseid kasutav Random Foresti mudel valideerimisandmestikul makro-F1 väärtuse 0,662. Kõrgus- ja mullastikutunnuste täielik lisamine viis tulemuse 0,653-ni. Automaatselt valitud 50 tunnusega mudeli makro-F1 oli 0,660 samas kui 18 käsitsi koostatud liigisignatuuri tunnusega mudel saavutas 0,564 (selgitus ptk 5.2). Automaatselt valitud tunnuste olulisuse vahe oli suhteliselt väike: kõige olulisema

tunnuse olulisus oli 0,018 ja 50. tunnuse oma 0,005, kuid 51. tunnuse olulisus (0,005) oli 50-ndaga praktiliselt võrdne, mistõttu 50 tunnuse piir oli mõnevõrra suvaline. Kasutatud hüperparameetrid (*min_samples_leaf*=2, piiranguta sügavus) olid samad, mis baasmudelil, kus võrdlus põhjaliku häälestusega ei näidanud olulist ülesobitamist (vt ptk 3.5.1).

Klasside tasakaalustamisel andis parima tulemuse klassikaalude kasutamine. Tasakaalustamata mudeli makro-F1 oli 0,636, klassikaaludega mudelil 0,660 ja käsitsi tehtud ülevalimiga mudelil 0,654 — klassikaalude ja tasakaalustamata mudeli vahe oli 0,024 ning klassikaalude ja ülevalimi vahe 0,006.

Random Foresti hüperparameetrite häälestamise järel saavutati makro-F1 väärtus 0,665. Kaheastmeline Random Foresti hierarhia saavutas 0,668 ja neljaastmeline hierarhia 0,646. Kontrollitud võrdluse parima valideerimistulemuse saavutas ühetasandiline häälestatud XGBoost, mille makro-F1 oli 0,707. Sama tunnustekomplektiga kaheastmelise XGBoosti hierarhia tulemus oli 0,687 ning neljaastmelise hierarhiaga mudeli tulemus 0,689.

Tabel 4.3. Tunnuste ja modelikomponentide kontrollitud võrdlus valideerimisandmestikul.

Võrreldav komponent	Mudelivariant	Val. õigsus	Val. makro-F1	Val. kappa	Val. HB F1	Val. KS F1	Val. KU F1	Val. MA F1
Sisendandmed	Ainult Sentinel-2 tunnused	0,845	0,662	0,786	0,61	0,86	0,69	0,91
Sisendandmed	Sentinel-2, kõik kõrgus- ja mullastik	0,843	0,653	0,783	0,59	0,85	0,69	0,91
Tunnuste esitus	Automaatselt valitud 50 tunnust	0,839	0,660	0,778	0,57	0,84	0,70	0,91
Tunnuste esitus	18 ise valitud liigisignatuuri tunnust	0,756	0,564	0,666	0,51	0,78	0,52	0,84
Klasside tasakaalustamine	Tasakaalustamata	0,840	0,636	0,772	0,43	0,83	0,71	0,91
Klasside tasakaalustamine	Klassikaalud	0,839	0,660	0,778	0,57	0,84	0,70	0,91
Klasside tasakaalustamine	Käsitsi ülevalim	0,838	0,654	0,771	0,54	0,84	0,69	0,90
Hüperparameetrid	Häälestatud Random Forest	0,839	0,665	0,778	0,62	0,84	0,70	0,91
Arhitektuur	Neljaastmeline Random Foresti hierarhia	0,838	0,646	0,774	0,59	0,85	0,66	0,91

Võrreldav komponent	Mudelivariant	Val. õigsus	Val. makro-F1	Val. kappa	Val. HB F1	Val. KS F1	Val. KU F1	Val. MA F1
Arhitektuur	Kaheastmeline Random Foresti hierarhia	0,844	0,668	0,783	0,64	0,85	0,69	0,91
Algoritm	Häälestatud ühetasandiline XGBoost	0,874	0,707	0,824	0,70	0,87	0,77	0,92
Arhitektuur ja algoritm	Kaheastmeline XGBoosti hierarhia	0,861	0,687	0,806	0,58	0,86	0,75	0,92
Arhitektuur ja algoritm	Neljaastmeline XGBoosti hierarhia (EXP038)	0,879	0,689	0,830	0,64	0,89	0,74	0,94

Tulemused näitavad, et kontrollitud ühe-komponendi-korraga võrdluses ei parandanud hierarhiline arhitektuur automaatselt tulemust. Kõrgeim valideerimise makro-F1 saavutati lihtsama ühetasandilise XGBoosti mudeliga (0,707), samas kui neljaastmeline hierarhia (EXP038) saavutas kõrgema õigsuse, Coheni kappa ning kaasiku ja männiku F1-skoori (tabel 4.3). Kuna valideerimisandmestikul ei andnud ükski koondmõõdik üheselt selget võitjat, ei saa üksnes selle komponentide eemaldamise uuringu põhjal järeldada, et lõpliku mudeli neljaastmeline ülesehitus oleks üldiselt parem kui ühetasandiline mudel. Neljaastmeline hierarhiline XGBoost (EXP038) valiti sellegipoolest lõplikuks mudeliks enne testandmestikul lõplike tulemusmõõdikute arvutamist, tuginedes valideerimisandmestikul saavutatud paremale õigsusele ja kappale ning ka seetõttu, et mudel suutis teistest paremini eristada mändi ja kaske, mis on enimlevinud puuliigid. Baasmudeli nõrkuseks oli just kaskede segiajamine teiste klassidega.

Komponentide võimaliku koosmõju kontrollimiseks tehti lisaks vastupidine komponentide eemaldamine, milles lähtuti lõpliku EXP038 mudeli täpsest konfiguratsioonist ja eemaldati korraga üks komponent. Lõpliku konfiguratsiooni valideerimise makro-F1 oli 0,689. Hierarhia, liigisignatuuri tunnuste või kõrgus- ja mullastikuandmete eemaldamisel tulemus vähenes (vt tabel 4.4). Käsitsi ülevalimi eemaldamine seevastu suurendas valideerimise makro-F1 väärtuseni 0,704.

Tabel 4.4. Lõpliku XGBoosti konfiguratsiooni komponentide (vt ptk 4.2 algus) eemaldamise mõju valideerimisandmestikul.

Mudelivariant	Valideerimise makro-F1
Lõplik konfiguratsioon 4-astmeline hierarhiline EXP038	0,689
Ilma käsitsi ülevalimita	0,704
Ilma hierarhilise arhitektuurita	0,682
Ilma liigisignatuuri tunnusteta	0,680
Ilma kõrgus- ja mullastikutunnusteta	0,682

Kuna konfiguratsioon fikseeriti enne testandmestikul lõplike tulemusmõõdikute arvutamist ja valideerimisandmestiku erinevus oli väike, jäeti käsitsi ülevalim sellele vaatamata lõplikku konfiguratsiooni sisse.

4.2.1 Kõrgus- ja mullastikutunnuste mõju

Kõrgus- ja mullastikutunnuste mõju sõltus kasutatud tunnustekomplektist ja mudeli ülesehitusest. Kontrollitud ühetasandilises võrdluses vähendas kõigi kõrgus- ja mullastikutunnuste lisamine (kõrgusandmed katsid 99,8% ja mullastikuandmed 100% eraldistest, ülejäänutel kasutati mediaanasendust) valideerimise makro-F1 väärtuse 0,662-lt 0,653-le. Lõpliku hierarhilise konfiguratsiooni korral vähendas samade tunnuserühmade eemaldamine valideerimise makro-F1 väärtuse 0,689-lt 0,682-le.

Automaatselt valitud 50 tunnuse hulka kuulusid neli kõrgustunnust: maksimaalne kõrgus, mediaankõrgus, kõrguse standardhälve ja keskmine kõrgus. Ükski enam kui 350 *one-hot*-kodeeritud mullatunnusest valitud 50 tunnuse hulka ei jõudnud.

Täielikku tunnustekomplekti kasutanud Random Foresti mudelis olid kõige olulisemad üksiktunnused kõrguse standardhälve, maksimaalne kõrgus, mediaankõrgus ja keskmine kõrgus. Seevastu lõpliku hierarhilise mudeli esimeses astmes oli kõrgus- ja mullastikutunnuste summaarne olulisus ligikaudu 1,2%. Need tulemused näitavad, et tunnuste olulisus sõltus nii mudeliastmest kui ka kasutatud tunnuste esitusest.

4.2.2 Informatiivsemad Sentinel-2 tunnused

Kuna hierarhiline mudel koosnes neljast eraldi alammodellist, ei olnud võimalik koostada üht kõiki astmeid üheselt kirjeldavat tunnuste olulisuse pingerida. Tabelis 4.5 on esitatud esimese astme rühmamudeli olulisemad tunnused. See alammodell rakendus kõigile eraldistele ja eristas okaspuid, lehtpuid ning klassi MUU.

Kõige olulisemaks üksiktunnuseks osutus augusti lõpu (29.08 kümnapäevane vaatlusperiood) lühilainelise infrapuna kanali B12 väärtus, mis moodustas 12,1% esimese astme tunnuste summaarsest olulisusest. Sellele järgnes käsitsi koostatud sügisene sanglepa signatuuritunnus „LM_autumn_index“ osakaaluga 11,4%. Aprillikuu NBR ja NDVI tunnuste osakaalud olid vastavalt 9,3% ja 5,3%. Augusti lõpu vaatlusperioodi pilvevaba kaadrikatvust teiste kümnapäevaste vahemikega eraldi ei võrreldud.

Tabel 4.5. Hierarhilise mudeli esimese astme olulisemad tunnused.

Tunnus	Ajavahemik	Osakaal tunnuste summaarsest olulisusest (%)
B12	Augusti lõpp	12,1
LM_autumn_index	Sügis	11,4
NBR	Aprill	9,3
NDVI	Aprill	5,3
Kõrguse- ja mullastikutunnused	-	ligikaudu 1,2

Olulisemad tunnused ei jaotunud aasta jooksul ühtlaselt, vaid koondusid peamiselt kevadesse ning hilissuvesse ja sügisse. Esimese astme tulemus kirjeldab siiski ainult okas- ja lehtpuude ning klassi MUU eristamiseks olulisi tunnuseid, mitte üksikute puuliikide omavaheliseks eristamiseks olulisi tunnuseid ega näita, millised tunnused olid kõige olulisemad kuusiku ja männiku või üksikute lehtpuuliikide omavahelisel eristamisel.

4.3 Parim mudel

Puhtpuistute põhiandmestikul hinnati neljaastmelist hierarhilist Random Foresti mudelit EXP032 ja sama arhitektuuriga XGBoosti mudelit EXP038. Neljaastmeline hierarhiline arhitektuur valiti lõplikuks ülesehituseks enne testandmestikul lõplike tulemusmõõdikute arvutamist, tuginedes valideerimisandmestiku tulemustele (tabel 4.3): EXP038 saavutas parema õigsuse, Coheni kapp ja kaasiku ja männiku F1-skoori, samas kui ühetasandiline mudel saavutas kõrgema makro-F1 ning parema haaviku ja kuusiku tulemuse. Kuna valideerimistulemus ei andnud üheselt selget eelistust, tehti valik koondnäitajate ja hierarhilise lähenemise põhimõttelise sobivuse alusel (vt ptk 4.2 võrdlus).

XGBoost saavutas testandmestikul kõigi koondmõõdikute järgi parema tulemuse kui Random Forest. XGBoosti õigsus oli 0,870 ja Coheni kapp 0,820, Random Forestil vastavalt 0,822 ja 0,753. XGBoosti makro-F1 oli 0,692, ületades Random Foresti tulemust 0,07 võrra (tabel 4.6).

Tabel 4.6. Hierarhiliste Random Foresti ja XGBoosti klassifitseerimismudelite tulemused testandmestikul.

Mõõdik	Random Forest	XGBoost
Õigsus	0,82	0,87
Tasakaalustatud täpsus	0,60	0,67
Makro-F1	0,63	0,69
Coheni kapp	0,75	0,82
Makro-F1 kuue põhipuuliigi kohta	0,73	0,81
Tasakaalustatud täpsus kuue põhipuuliigi kohta	0,70	0,78

Klass MUU sisaldas testandmestikus ainult üht eraldist ja kumbki mudel seda õigesti ei klassifitseerinud. Seetõttu mõjutas selle klassi tulemus ebaproportsionaalselt makro-F1 ja tasakaalustatud täpsuse väärtust. Kui MUU jäeti arvutusest välja, suurenes Random Foresti makro-F1 väärtus 0,625-lt 0,730-le ja XGBoosti väärtus 0,692-lt 0,807-le. Ka kuue põhipuuliigi põhjal arvutatud mõõdikute järgi jäi XGBoost paremaks mudeliks.

Mõlema algoritmiga klassifitseeriti kõige täpsemalt männikuid ja kaasikuid (tabel 4.7). Random Foresti mudel saavutas männiku F1-skooriks 0,910 ja kaasiku F1-skooriks 0,853. XGBoosti vastavad väärtused olid 0,927 ja 0,899.

Kõige keerulisem oli haavikute tuvastamine. Random Foresti mudeli haaviku F1-skoor oli 0,516 ja XGBoosti mudelil 0,627. XGBoost parandas märgatavalt ka sanglepiku klassifitseerimist: F1-skoor suurenes 0,699-lt 0,852-le. Kuusiku F1-skoor suurenes 0,669-lt 0,729-le ning hall-lepiku F1-skoor 0,726-lt 0,807-le.


Tabel 4.7. Random Foresti ja XGBoosti klassipõhised tulemused testandmestikul.

Puuliik	Random Forest			XGBoost		
	Täpsus	Saagis	F1	Täpsus	Saagis	F1
Männikud (MA)	0,921	0,898	0,910	0,922	0,932	0,927
Kaasikud (KS)	0,799	0,916	0,853	0,869	0,932	0,899
Kuusikud (KU)	0,688	0,651	0,669	0,770	0,692	0,729
Hall-lepikud (LV)	0,738	0,714	0,726	0,815	0,799	0,807
Sanglepikud (LM)	0,879	0,580	0,699	0,932	0,784	0,852
Haavikud (HB)	0,632	0,436	0,516	0,681	0,582	0,627
Muu (MUU)	0,000	0,000	0,000	0,000	0,000	0,000

XGBoosti veamaatriks on esitatud joonisel 4.2. Mudeli esimene aste, mis eristas okaspuid, lehtpuid ja klassi MUU, saavutas testandmestikul täpsuse 95,1%. Suurim osa lõplikest klassifitseerimisvigadest tekkis siiski lehtpuuliikide vahel.

Haavikuid klassifitseeriti kõige sagedamini kaasikutena: 55 haavikueraldisest sai kaasiku prognoosi 11 ehk 20%. Hall-lepikute puhul oli samuti suurimaks eksimusklassiks kaasikud. Kaasikuks klassifitseeriti 25 halli-lepiku eraldist 154-st ehk 16%. Kõik need eraldised jõudsid hierarhia esimesest astmest õigesti lehtpuude harusse, kuid klassifitseeriti hall-lepiku ja ülejäänud lehtpuude eristamise astmel valesti ülejäänud lehtpuude rühma.

Kuusikute 169 eraldisest klassifitseeriti 23 männikuks ja 16 kaasikuks. Männiku tulemused paiknesid valdavalt veamaatriksi diagonaalil: õigesti tuvastati 93,2% männieraldistest ja männikuks klassifitseeritud eraldistest 92,2% olid tegelikult männipuistud.



Joonis 4.2. Hierarhilise XGBoosti mudeli veamaatriks testandmestikul.

Random Foresti ja XGBoosti prognooside erinevuse statistiliseks hindamiseks kasutatud McNemari test näitas, et mudelite erinevus oli statistiliselt oluline. Testandmestiku 1510 eraldisest oli 97 juhul XGBoosti prognoos õige ja Random Foresti prognoos vale. Vastupidiseid juhtumeid, kus Random Forest oli õige ja XGBoost vale, oli 28. McNemari täpse testi olulisuse tõenäosus oli $p < 0,001$.

Viie tuhande *bootstrap*-taasvalimi põhjal oli Random Foresti õigsuse 95%-line usaldusvahemik 0,80–0,84 ja XGBoosti usaldusvahemik 0,85–0,88. Kuue põhipuuliigi makro-F1 usaldusvahemik oli Random Forestil 0,70–0,76 ja XGBoostil 0,77–0,83. XGBoosti ja Random Foresti mõõdikute erinevus oli XGBoosti kasuks kõigis 5000 taasvalimis.

4.4 Tulemused puistu vanuse järgi

XGBoosti mudeli tulemuslikkust hinnati eraldi alla 20-aastastes ja vähemalt 20-aastastes puistutes. Alla 20-aastaste puistute rühma kuulus 426 ning vähemalt 20-aastaste puistute rühma 1084 testandmestiku eraldist.

Vanemate puistute õigsus oli 0,920 ning nooremate puistute õigsus 0,742 (tabel 4.8). Kaalutud F1-skoor (valem 6) suurenes 0,739-lt 0,918-le. Kuue põhipuuliigi makro-F1 (valem 5) ja tasakaalustatud täpsus olid samuti vanemates puistutes selgelt suuremad (makro-F1 0,728 vs 0,854; tasakaalustatud täpsus 0,710 vs 0,833) — testandmestiku ainus klassi MUU eraldis kuulus vanemate puistute rühma, mistõttu seitsmeklassilise makro-F1 kasutamine oleks vanemate puistute tulemust ekslikult alahinnanud. Vanuserühmade lõikes olid vale klassifikatsiooniga eraldised statistiliselt oluliselt madalamad (keskmine kõrgus 12,8 m vs. 15,5 m õigesti klassifitseeritud eraldistel; Mann-Whitney U test, $p < 0,001$) ja suurema eraldisesisese kõrguse varieeruvusega (standardhälve 5,26 vs. 3,43; $p < 0,001$), mis viitab sellele, et madalama ja struktuurilt ebaühtlasema võrastikuga puistud on kaugseirepõhiselt raskemini eristatavad. Eraldiste visuaalset võrdlust ortofotoga ei tehtud.

Tabel 4.8. XGBoosti mudeli EXP038 tulemused puistu vanuse järgi

Vanuserühm	Eraldiste arv	Õigsus	Tasakaalustatud täpsus	Makro-F1	Kaalutud F1
Alla 20 aasta	426	0,742	0,710	0,728	0,739
Vähemalt 20 aastat	1084	0,920	0,833	0,854	0,918

Liikide lõikes oli vanuserühmade erinevus kõige suurem männikutel, mille F1-skoor suurenes 0,72-lt 0,95-le. Haavikute F1-skoor suurenes 0,55-lt 0,78-le, kaasikute tulemus 0,78-lt 0,94-le ning kuusikute tulemus 0,67-lt 0,79-le. Sanglepikute F1-skoor oli mõlemas vanuserühmas 0,85 ja hall-lepikute tulemus muutus 0,80-lt 0,81-le. Vanuserühmade F1-erinevuste seost boniteedi, eraldise suuruse, piirkonna või kaaspuuliikidega eraldi ei analüüsitud.

4.5 Segapuistute kaasamine ja puistu koosseisu prognoosimine

4.5.1 Klassifitseerimistulemused laiendatud andmestikul

Segapuistute mõju hindamiseks treeniti sama hierarhilise arhitektuuriga Random Foresti ja XGBoosti mudelid laiendatud andmestikul, mis sisaldas nii puht- kui ka segapuistuid. Laiendatud andmestiku testeraldistes oli puuliikide osakaal 20–100%.

Puht- ja segapuistuid sisaldaval laiendatud andmestikul oli klassifitseerimisülesanne oluliselt raskem ning mudelite tulemuslikkus väiksem kui puhtpuistute põhiandmestikul: testandmestikul oli Random Foresti õigsus 0,571 ja makro-F1 0,418, XGBoostil vastavalt 0,620 ja 0,478 (võrreldes puhtpuistute 0,822/0,625 ja 0,870/0,692-ga, tabel 4.9). XGBoost ületas Random Forestit ka laiendatud andmestikul.

Tabel 4.9. Random Foresti ja XGBoosti klassifitseerimistulemused testandmestikul puhtpuistute ning puht- ja segapuistuid sisaldaval andmestikul

Mudel	Andmestik	Õigsus	Makro-F1	Coheni kappa
Random Forest EXP032	Puhtpuistud	0,822	0,625	0,753
XGBoost EXP038	Puhtpuistud	0,870	0,692	0,820
Random Forest EXP048	Puht- ja segapuistud	0,571	0,418	0,408
XGBoost EXP049	Puht- ja segapuistud	0,620	0,478	0,481

4.5.2 Puuliikide osakaalude prognoosimine

Puistu puuliigilise koosseisu prognoosimiseks koostati laiendatud andmestikul Random Foresti mitmeväljundiline regressioonimudel (EXP050) ja XGBoosti regressioonimudel (EXP076). Mudelid prognoosisid iga eraldise kohta seitsme puuliigiklassi osakaalu.

XGBoost saavutas kõigi puuliikide puhul Random Forestist suurema determinatsioonikordaja ja väiksema keskmise absoluutvea. Kõige suurem determinatsioonikordaja saavutati männi osakaalu prognoosimisel: Random Forestil 0,50 ja XGBoostil 0,59. Kuuse osakaalu prognoosimisel olid vastavad väärtused 0,36 ja 0,42 ning kase puhul 0,31 ja 0,40 (tabel 4.10).

Tabel 4.10. Puistu puuliigilise koosseisu prognoosimise tulemused testandmestikul.

Puuliik	Algoritm	R²	MAE, protsendipunkti	RMSE, protsendipunkti
Haab (HB)	Random Forest	0,29	8,6	15,0
Haab (HB)	XGBoost	0,34	7,9	14,5
Kask (KS)	Random Forest	0,31	21,4	26,3
Kask (KS)	XGBoost	0,40	19,3	24,6
Kuusk (KU)	Random Forest	0,36	14,5	20,6
Kuusk (KU)	XGBoost	0,42	13,4	19,6
Sanglepp (LM)	Random Forest	0,24	7,8	13,2
Sanglepp (LM)	XGBoost	0,29	7,0	12,7
Hall lepp (LV)	Random Forest	0,32	8,8	16,8
Hall lepp (LV)	XGBoost	0,35	8,1	16,4
Mänd (MA)	Random Forest	0,50	18,1	24,4
Mänd (MA)	XGBoost	0,59	15,8	22,1
Muu (MUU)	Random Forest	0,10	3,6	9,6
Muu (MUU)	XGBoost	0,13	3,5	9,5


Liikideülene keskmine absoluutviga oli Random Forestil 11,8 ja XGBoostil 10,7 protsendipunkti. Absoluutarvuliselt oli suurim keskmine viga kase osakaalu prognoosimisel: Random Forestil 21,4 ja XGBoostil 19,3 protsendipunkti. Väikseim viga saadi klassi MUU puhul, kuid selle tulemust mõjutasid valdavalt nullilähedased tegelikud osakaalud.

Prognoositud koosseisust tuletati ka enamuspüülik, valides iga eraldise kohta suurima prognoositud osakaaluga klassi. Random Foresti regressioonimudelitest tuletatud enamuspüüliigi õigsus oli 0,610 ja makro-F1 0,434. XGBoosti regressioonimudelitest tuletatud enamuspüüliigi õigsus oli 0,637, makro-F1 0,488 ja Coheni kappa 0,500. Mõlemad regressioonimudelitest tuletatud tulemused olid sama laiendatud andmestiku otsestest klassifitseerimismudelitest veidi paremad: Random Foresti otseste klassifitseerija makro-F1 oli 0,418 ja XGBoosti klassifitseerija tulemus 0,478 (vt tabel 4.9). Selle erinevuse statistilist olulisust (usaldusvahemike ega paaristestiga) eraldi ei kontrollitud, mistõttu ei saa regressioonist tuletatud enamuspüüliigi tulemust pidada otsestest klassifitseerimismudelitest kindlalt paremaks. Seetõttu kasutati ptk 3.8 kirjeldatud pikslipõhise püüliigikaardi koostamiseks otsest hierarhilist klassifitseerimismudelit, mitte koosseisu regressioonimudelitest tuletatud enamuspüüliiki.

4.6 Pikslipõhine puuliigikaart

XGBoosti mudeli põhjal koostati Lääne-Eesti alamregiooni kohta pikslipõhine enamuspuuliigi kaart. Kaardistatud metsapindala oli 2833,6 km². Uurimisala jaotati kaardistamiseks 15 eraldiseisvaks 25×25 km ruuduks (CDSE andmete allalaadimispiirangute tõttu), millest 14 sisaldasid metsamaski läbinud piksleid; üks ruut osutus kümne meetrise lahtusega kontrollimisel metsapiksliteta alaks.

XGBoosti kaardil moodustas kask 41,8%, mänd 27,8%, kuusk 12,7%, hall lepp 8,8%, haab 5,2%, sanglepp 3,6% ja klass MUU 0,1% kaardistatud metsapindalast (joonis 4.3).



Joonis 4.3. Hierarhilise XGBoosti mudeliga koostatud pikslipõhine enamuspuuliigi kaart Lääne-Eesti alamregioonis; kujutatud on väljavõte kaardi ühest osast.

Kaardi kontrollimiseks määrati iga metsaregistri eraldise piires kaardipõhine enamuspuuliik pikslite häälteenamuse põhjal. Puhtpuistute põhiandmestikuga tehtud võrdluses kasutati 6282 eraldist, mille piires oli vähemalt viis kehtivat pikslit. Võrdlusesse kuulusid ka mudelite treening- ja valideerimisandmestikku kuulunud eraldised, mistõttu tegemist ei ole sõltumatu valideerimisega.

Kaardipõhine enamuspuliik langes registriandmetega kokku 93,9%-l eraldistest (tabel 4.11). Liikide lõikes oli vastavus kõrgeim männikul (0,979) ja kaasikul (0,967), madalaim sanglepikul (0,701) ja klassil MUU (0,077).

Tabel 4.11. Pikslipõhise kaardi vastavus puhtpuistute põhiandmestiku eraldiste enamuspuliigile

Puuliik	Eraldiste arv	Vastavus
Männikud (MA)	2744	0,979
Kaasikud (KS)	2201	0,967
Hall-lepikud (LV)	598	0,831
Kuusikud (KU)	372	0,871
Sanglepikud (LM)	204	0,701
Haavikud (HB)	150	0,800
Muu (MUU)	13	0,077
Kokku	6282	0,939

Laiendatud andmestikuga tehtud võrdluses kasutati 8589 eraldist. Kaardipõhine enamuspuliik langes eraldise suurima osakaaluga liigiga kokku 72,9%-l juhtudest. Puhtpuistutes oli vastavus 87,8% ja segapuistutes 62,9% (tabel 4.12).

Tabel 4.12. Puuliigikaardi vastavus laiendatud andmestiku eraldistele puistutüübiti.

Puistutüüp	Eraldiste arv	Vastavus
Kõik eraldised	8589	0,729
Puhtpuistud	3461	0,878
Segapuistud	5128	0,629

Segapuistutes oli enamuspuliigi vastavus kõige väiksem haaval ja sanglepal, vastavalt 26,2% ja 27,1%. Mäni vastavus oli 71,5% ja kase vastavus 80,0%.

Kaardi ja metsaregistri eraldiste võrdlust ei käsitleta sõltumatu kaarditäpsuse hinnanguna. Võrdluses sisaldasid ka mudelite treening- ja valideerimisandmestikku kuulunud eraldised ning eraldise pikslite enamushääletus vähendas üksikute valesti klassifitseeritud pikslite mõju. Tulemused näitavad seetõttu eelkõige mudeli ja kaardistusvoo kooskõla kasutatud registriandmetega. Pikslipõhise kaardi tulemuste tähendust, ruumilise toe erinevust (pikslite ja eraldiste mastaabi vahel) ja sõltumatu valideerimise vajadust käsitletakse järgmises peatükis.

5. Arutelu

5.1 Enamuspuuliigi klassifitseerimine

Töö tulemused näitasid, et Sentinel-2 aegridade põhjal oli võimalik klassifitseerida Lääne-Eesti alamregiooni enamuspuuliiki hea täpsusega. Parim hierarhiline XGBoosti mudel saavutas testandmestikul õigsuse 0,870, makro-F1 väärtuse 0,692 ja Coheni kappa 0,820. Sama andmestiku ja hierarhilise arhitektuuriga Random Foresti mudeli vastavad tulemused olid 0,822, 0,625 ja 0,753. McNemari test ja *bootstrap*-usaldusvahemikud näitasid, et XGBoosti paremus ei piirdunud üksnes ühe koondmõõdikuga, vaid avaldus samade testeraldise prognooside võrdlemisel läbivalt.

XGBoosti parem tulemus võib olla seotud algoritmi võimega parandada järjestikku eelnevate otsustuspuude vigu ning kirjeldada keerukaid seoseid suure ja omavahel korreleerunud tunnuste arvuga andmestikus. Random Forest moodustab puud üksteisest sõltumatult, mistõttu võib see olla stabiilsem ja lihtsamini tõlgendatav, kuid käesoleva andmestiku korral ei saavutanud see XGBoostiga samaväärset täpsust. Tulemus ei tähenda siiski, et XGBoost oleks puuliikide klassifitseerimisel alati Random Forestist parem. Algoritmide paremus võib sõltuda andmestiku suurusest, tunnuste esitusest, klassijaotusest ja hüperparameetritest.

Saadud mudeli õigsus oli suurem kui Lang jt (2018) Eesti-üleses uuringus saavutatud 75,5%, kuid väiksem kui mõnes Kesk-Euroopa uuringus esitatud ligikaudu 90–96% täpsus (Grabska jt, 2019; Immitzer jt, 2019; Hemmerling jt, 2021). Neid tulemusi ei saa otseselt võrrelda, sest uuringud erinesid puuliikide arvu, uurimisala, referentsandmete, sisendtunnuste ja valideerimisskeemi poolest. Näiteks kasutas Lang jt (2018) võrdlusandmestikuna 1529 riikliku metsainventeerimise valimipunkti, kus ühe puuliigi osakaal oli vähemalt 75%, mitte metsaregistri eraldisi nagu käesolevas töös.

Kõige paremini klassifitseeriti männikuid ja kaasikuid. Nende klasside head tulemust toetas nii suur eraldiste arv treeningandmestikus kui ka suhteliselt selge spektraalne ja fenoloogiline eristatavus. Mänd erines lehtpuudest kogu kasvuperioodi vältel ning kaasik oli lehtpuuklassidest kõige arvukam. Kuusk on samuti okaspuuna lehtpuudest spektraalselt selgelt eristatav. Kuuse nõrgem tulemus baasmudelil võis olla seotud selle väiksema esindatusega treeningandmestikus (vt ptk 4.1); lõpliku mudeli märgatavalt parem kuuse F1-skoor näitab, et liik oli kasutatud tunnuste põhjal eristatav, kuid baasmudeli ja lõpliku mudeli vahel muutusid korraga nii andmete puhastamine, tunnused, klasside tasakaalustamine kui ka

mudeliarhitektuur, mistõttu ei saa paranemist omistada üksnes esindatuse erinevusele. Kõige keerulisem oli haaviku klassifitseerimine, mille XGBoosti F1-skoor oli 0,627. Haavikut klassifitseeriti kõige sagedamini kaasikuna, mis võib viidata nende liikide spektraalsete tunnuste osalisele kattumisele. Tulemust võis mõjutada ka kaseklassi märksa suurem esindatus treeningandmestikus, kuid seda mõju eraldi ei testitud. Haava nõrgemat eristatavust on täheldatud ka Eesti varasemates uuringutes (Kaha, 2017; Lang jt, 2018).

XGBoost parandas Random Forestiga võrreldes F1-skoori kõigi kuue põhipuuliigi klassi puhul. Eriti suur oli paranemine sanglepiku puhul, mille F1-skoor suurenes 0,699-lt 0,852-le. Samuti paranesid haavikute, hall-lepikute ja kuusikute tulemused. See näitab, et XGBoost ei suurendanud üksnes arvukamate klasside õigsust, vaid parandas ka mitme väiksema klassi eristamist.

Klassi MUU tulemust ei olnud võimalik sisuliselt hinnata, sest testandmestikus oli ainult üks sellesse klassi kuuluv eraldis. Selle objekti valesti klassifitseerimine vähendas ebaoproportsionaalselt makro-F1 ja tasakaalustatud täpsuse väärtust. Kuue põhipuuliigi põhjal arvutatud XGBoosti makro-F1 oli 0,807, mis kirjeldab mudeli toimimist põhiliste puuliikide puhul paremini kui seitsme klassi tulemus. Samas ei lahenda klassi väljajätmine selle vähese esindatuse probleemi. Usaldusväärseks hindamiseks oleks vaja märksa rohkem sellesse rühma kuuluvaid eraldisi või tuleks MUU klass modelleerimisest eemaldada.

Puistu vanus oli mudeli tulemuslikkusega selgelt seotud. Alla 20-aastaste puistute õigsus oli 0,742, vähemalt 20-aastastel puistutel aga 0,920. Noortes ja hõredamates puistutes mõjutavad satelliidilt mõõdetavat peegeldust lisaks puude võrastikule maapind, alustaimestik ja puistu ebaühtlane struktuur. Vanemates puistutes on liigile iseloomulik võrastik paremini välja kujunenud ja moodustab suurema osa Sentinel-2 piksli signaalist. Sarnast, kuigi tunduvalt tagasihoidlikumat seost puistu vanuse ja klassifitseerimistäpsuse vahel täheldasid ka Lang jt (2018), kelle enamuspuuliigi õigsus paranes 75,5%-lt (kõik vanuserühmad) 78,4%-le, kui arvestati üksnes üle 20-aastaseid puistuid.

Kuue põhipuuliigi makro-F1 ja tasakaalustatud täpsus olid samuti vanemates puistutes selgelt suuremad kui nooremates (makro-F1 0,854 vs 0,728; tasakaalustatud täpsus 0,833 vs 0,710). Vanuserühmade erinevus avaldus seega läbivalt nii üld- kui klassipõhistes mõõdikutes, mitte üksnes sagedasemate liikide (mänd, kask) õigsuse paranemises.

5.2 Sentinel-2 aegrea ja tunnuste valiku mõju

Hierarhilise mudeli esimese astme tunnuste olulisuse analüüs näitas, et okas- ja lehtpuude ning klassi MUU eristamiseks oluline informatsioon ei jaotunud aasta jooksul ühtlaselt, vaid pärines peamiselt kevadest ning hilissuvest ja sügisest. Kõige olulisem üksiktunnus oli augusti lõpu lühilainelise infrapuna kanal B12; oluliste tunnuste hulka kuulusid ka aprilli NBR ja NDVI ning käsitsi koostatud sügisene liigisignatuuri tunnus. Üksikute puuliikide omavahelise eristamise kohta ei võimalda esimese astme tunnuste olulisus samaväärseid järeldusi teha.

Kevadised vaatlused kirjeldavad puuliikide erinevat lehtimise algust ja taimkatte aktiivsuse suurenemist. Hilissuve ja sügise tunnused kajastavad lehtede pigmentatsiooni, veesisalduse ja vananemise erinevusi. Lühilainelise infrapuna kanalite tähtsus on kooskõlas Kaha (2017), Grabska jt (2019) ja Immitzer jt (2019) tulemustega, mille kohaselt annavad punaserva-, lähiinfrapuna- ja lühilainelise infrapuna kanalid puuliikide eristamisel rohkem informatsiooni kui ainult nähtava spektri kanalid.

Tulemused näitasid, et puuliikide eristamiseks olulised tunnused pärinesid aasta erinevatest perioodidest, mis toetab eri fenoloogilisi etappe hõlmavate Sentinel-2 aegride kasutamist; samas ei olnud kõik aegrea osad võrdselt informatiivsed. Tiheda aegrea väärtus ei tulene pelgalt vaatluste suurest arvust. Aegrida võimaldab analüüsida kogu hooajalist arengut ning välja selgitada perioodid, mil liikidevahelised erinevused avalduvad kõige selgemalt. Ilma terve kasvuperioodi vaatlusteta oleks informatiivsete ajavahemike valik tõenäoliselt sõltunud üksikutest ette määratud stseenidest ja nende pilvisusest.

Automaatselt valitud Top-50 tunnustega mudel saavutas valideerimisandmestikul makro-F1 väärtuse 0,660, võrreldes kõiki Sentinel-2, kõrgus- ja mullastikutunnuseid kasutanud mudeli väärtusega 0,653 (vt ptk 4.2, tabel 4.3). Tunnuste arvu vähendamine seega tulemust ei halvendanud. See viitab tunnuste infosisu suurele kattuvusele. Aegrea osade kattuvus tuleneb mitmest allikast: lähestikused ajahetked kirjeldavad sarnast fenoloogilist seisundit, erinevad spektrikanalid on omavahel korreleerunud ning kanalitest tuletatud vegetatsiooniindeksid dubleerivad suures osas juba kanalites sisalduvat informatsiooni.

Sarnasele järeldusele jõudsid Lechner jt (2022), kes vähendasid 617 tunnusest kasutusse 50 ilma täpsust kaotamata. Grabska jt (2019) saavutasid viie valitud ajahetke (stseeni) kasutamisel parema tulemuse kui kõigi stseenide kasutamisel — tegemist oli ajaliste vaatluste, mitte üksiktunnuste valikuga, kuid tulemus toetab sama üldist järeldust: rohkem sisendandmeid ei taga automaatselt paremat mudelit. Seega ei taga suurem tunnuste arv automaatselt paremat

üldistusvõimet, kuid see, kas tunnuste vähendamine säilitab mudeli täpsuse, sõltub nende valimise viisist.

Käsitsi koostatud 18 liigisignatuuri tunnusega mudeli kontrollitud valideerimistulemus oli automaatselt valitud Top-50 tunnuste tulemusest madalam. Samas vähendas nende tunnuste eemaldamine lõplikust konfiguratsioonist valideerimise makro-F1 väärtust 0,689-lt 0,680-le. Need näiliselt vastandlikud tulemused näitavad, et tunnuste mõju sõltus nende koostoimest ülejäänud sisendtunnuste, algoritmi ja mudeliarhitektuuriga. Käsitsi koostatud tunnused ei olnud eraldiseisva tunnustekomplektina piisavad, kuid võisid täielikku aegrida kasutavas hierarhilises mudelis anda täiendavat informatsiooni.

Selle järelduse tõlgendamisel tuleb siiski arvestada, et liigisignatuuride kujundamisel kasutati uurivaks analüüsiks kogu andmestikku. Seetõttu ei ole võimalik nende tegelikku üldistusvõimet olemasoleva testandmestiku põhjal täielikult sõltumatult hinnata.

Ka hüperparameetrite mõju ei olnud väga suur ega ühesuunaline. Random Foresti häälestamine suurendas kontrollitud võrdluses valideerimise makro-F1 väärtuse 0,660-lt 0,665-le, kuid erinevate mudelikonfiguratsioonide tulemused näitasid, et mõju sõltus ka tunnuste ja arhitektuuri koostoimest (tabel 4.3). Eraldi ei uuritud XGBoosti õppimiskõverat (õppimiskiiruse ja puude arvu vahetada), mis võib samuti mudeli tulemuslikkust mõjutada. Ühel valideerimisjaotusel saavutatud väikesed erinevused ei pruugi teisele ruumilisele andmejaotusele üldistuda. Usaldusväärsema hüperparameetrite valiku jaoks tuleks kasutada korduvat ruumilist ristvalideerimist.

5.3 Kõrgus- ja mullastikuandmete ning mudeliarhitektuuri mõju

Kõrgus- ja mullastikuandmete mõju ei olnud kõigis katsetes ühesuunaline. Kontrollitud ühetasandilises võrdluses vähendas nende lisamine valideerimise makro-F1 väärtuse 0,662-lt 0,653-le. Lõpliku hierarhilise mudeli konfiguratsioonist samade tunnuste eemaldamine vähendas aga makro-F1 väärtuse 0,689-lt 0,682-le. Seega sõltus lisaandmete mõju sellest, milliste tunnuste ja mudeliarhitektuuriga neid kombineeriti.

Automaatselt valitud 50 tunnuse hulka kuulus neli kõrgustunnust, kuid ükski mullatunnus sinna ei jõudnud. See viitab sellele, et kõrgustunnused sisaldasid mudeli jaoks täiendavat informatsiooni puistu struktuuri kohta. Kõrguse keskmine, mediaan, maksimum ja standardhälve võisid aidata eristada liike või liigirühmi, mille tüüpiline kasvukiirus ja puistu struktuur on erinevad.

Mullastikutunnuste tagasihoidlik mõju erines Lang jt (2018) tulemustest, kus mullastikuandmed olid Eesti puuliigikaardi koostamisel olulised. Erinevust võib selgitada mullakoodi liiga peen granulaarsus: mudelisse läks ligikaudu 350 erinevat pindalaliselt domineerivat mullakoodi (vt ptk 4.2.1), mis one-hot-esituses hajutab iga koodi statistilise kaalu paljude harvaesinevate tunnuste vahel. Detailne mullakood teisendati seetõttu suureks arvuks hõredateks indikaatortunnusteks (teisendus ise on pööratav ega kaota infot, kuid võis vähendada üksikute mullakategooriate informatiivsust ja raskendada nende mõju õppimist). Laiemate pedoökoloogiliste rühmade või kasvukohatüüpide kasutamine võiks olla puuliikide modelleerimisel informatiivsem kui üksikute mullakoodide one-hot-esitus.

Hierarhilise arhitektuuri mõju erines kontrollitud valideerimiskatse ja lõpliku konfiguratsiooni vahel: Kontrollitud valideerimiskatses saavutas ühetasandiline XGBoost makro-F1 väärtuse 0,707, ületades nii kaheastmelise (0,687) kui ka neljaastmelise hierarhia (0,689) tulemust. Lõpliku konfiguratsiooni vastupidises komponendi eemaldamises vähendas hierarhia eemaldamine tulemust aga just vastupidises suunas, 0,689-lt 0,682-le. Seega ei saa järeldada, et hierarhiline arhitektuur oleks üldiselt ühetasandilisest mudelist parem — selle kasulikkus sõltus ülejäänud konfiguratsioonist. See tulemuste ebajärjekindlus väärrib süstemaatilist edasist uurimist, näiteks hierarhia kasulikkuse testimist mitme sõltumatu andmejaotuse peal.

Hierarhia võimalik eelis seisneb selles, et igas etapis lahendatakse väiksem ja sisuliselt selgem klassifitseerimisülesanne. Näiteks käsitletakse okas- ja lehtpuid esmalt laiade rühmadena ning alles seejärel eristatakse nende sees sarnasemaid liike. Samal ajal kanduvad esimese astme vead järgmistesse etappidesse edasi. Kui eraldi suunatakse valesse liigirühma, ei ole järgmistel alamudelitel enam võimalik õiget liiki prognoosida. Hierarhia sobivus sõltub seetõttu esimese astme täpsusest ja sellest, kas klasside rühmitamine vastab tegelikele spektraalsetele erinevustele.

Lõplik hierarhiline XGBoost saavutas puhtpuistute lõppmudelite võrdluses suurima testitäpsuse (õigsus 0,870), kuid seda tulemust ei saa omistada ainult hierarhiale. Mudel erines varasematest variantidest korraga algoritmi, tunnuste, klasside tasakaalustamise ja arhitektuuri poolest. Kontrollitud katsed näitasid, et nende komponendi mõju ei olnud lihtsalt liidetav, vaid sõltus koostoimest.

5.4 Segapuistud ja puistu puuliigilise koosseisu prognoosimine

Puht- ja segapuistuid sisaldaval laiendatud andmestikul oli klassifitseerimisülesanne testandmestikul oluliselt raskem kui puhtpuistute põhiandmestikul: Random Foresti makro-F1

oli 0,418 ja XGBoostil 0,478, mõlemad selgelt madalamad kui puhtpuistute vastavad tulemused (0,625 ja 0,692). XGBoost jäi Random Forestist paremaks ka laiendatud andmestikul.

Puhtpuistus pärineb suurem osa satelliidilt mõõdetavast võrastiku signaalist ühelt puuliigilt ning enamuspuuliigi klass vastab sellele suhteliselt hästi. Segapuistus moodustub eraldise keskmine spektraalne signaal mitme liigi, alusmetsa ja puistu struktuuri koosmõjul. Ühe enamuspuuliigi määramine ei kirjelda sellist signaali täielikult. Näiteks võib 40% osakaaluga enamuspuuliigi spektraalne mõju olla väiksem kui ülejäänud liikidel kokku, sest liikide erinev võrastiku kõrgus ja peegelduvus mõjutavad nende panust spektraalsesse signaali rohkem kui pelgalt pindalaline osakaal, kuid klassifitseerimismudeli sihtväärtuseks jääb ikkagi üks liik.

Laiendatud andmestiku tulemused näitavad, et segapuistute enamuspuuliigi määramine oli puhtpuistutega võrreldes keerulisem ka siis, kui segapuistud olid treeningandmestikku kaasatud. Enamuspuuliigi klass ei kirjelda ülejäänud puuliigilist koosseisu ning seetõttu võib ühe klassi prognoosimine olla väikese enamuspuuliigi osakaaluga eraldistes ebapiisav.

Puistu koosseisu regressioon võimaldas prognoosida iga liigi osakaalu eraldi. XGBoost ületas Random Forestit kõigi liikide determinatsioonikordaja ja keskmise absoluutvea järgi. Testandmestikul saavutati parim tulemus männi osakaalu prognoosimisel, mille R^2 oli 0,59. Kase ja kuuse vastavad väärtused olid 0,40 ja 0,42. Liikideülene keskmine absoluutviga oli XGBoostil 10,70 protsendipunkti.

Saadud R^2 - ja veamõõdikud näitavad, et puuliikide täpsete osakaalude prognoosimine jäi märkimisväärse määramatusega ülesandeks. Metsaregistris esitatud osakaalud on välitööl hinnatud väärtused, mille täpsus võib liikide, inventeerijate ja puistu struktuuri vahel erineda. Metsa korraldamise juhendi kohaselt ei tohi koosseisukordaja määramise viga ületada 15 protsendipunkti latimetsades ja vanemates puistutes ning 25 protsendipunkti noorendikes (Metsa korraldamise juhend, 2024, § 13 lg 2). Samuti ei pruugi eraldise tagavarapõhine koosseis vastata täpselt Sentinel-2 piksli pindala- või võrastikupõhisele spektraalsele osakaalule.

Regressioonimudelitest tuletatud enamuspuuliigi makro-F1 oli mõlema algoritmi puhul veidi suurem kui samal laiendatud andmestikul otseselt treenitud klassifitseerimismudelil. XGBoosti puhul olid vastavad väärtused 0,488 ja 0,478 ning Random Forestil 0,434 ja 0,418. Erinevus oli väike, kuid sama suund ilmnis mõlema algoritmi korral. Üks võimalik selgitus on, et regressioon lubab mudelil esitada mitme liigi samaaegset esinemist ning enamuspuuliik

määratakse alles prognoositud osakaalude põhjal. Otsene klassifitseerimine sunnib mudelit valima ühe klassi ka piiripealsete ja peaaegu võrdsete osakaaludega eraldiste puhul.

Koosseisu prognoosimisel kasutatud lahendus ei arvestanud siiski täielikult kompositsioonandmete struktuuri. XGBoosti puhul prognoositi iga liigi osakaalu eraldi regressioonimudeliga, Random Forest kasutas mitmeväljundilist regressiooni; kumbki lahendus ei rakendanud siiski õppimise ajal otseselt kompositsioonandmetele omast mittenegatiivsuse ja ühiksumma piirangut. Edasistes uuringutes tuleks võrrelda seda kompositsioonandmetele mõeldud meetodite või mudelitega, mis arvestavad neid piiranguid juba õppimisel.

5.5 Metoodilised piirangud ja tulemusi mõjutavad tegurid

Uuringu esimene piirang tuleneb referentsandmetest. Metsaregistri puuliigiline koosseis määratakse valdavalt välitöödel hinnanguliselt ning võib sisaldada mõõtmis-, sisestus- ja tõlgenduserinevusi. Inventeerimise ja 2025. aasta satelliidivaatluste vahele jäi mitu aastat, mille jooksul puistu võis raiete, kahjustuste või loodusliku arengu tõttu muutuda. Lageraiekihtide ja metsateatiste kasutamine vähendas seda riski, kuid tsentroidipõhine kontroll ei pruukinud tuvastada eraldise osalist raiet või muud ruumiliselt piiratud muutust.

Teiseks hõlmas uurimus ainult Lääne-Eesti alamregiooni. See vähendas kasvukohtade varieeruvust, mistõttu käesolevas töös treenitud konkreetne mudel ei pruugi teistes Eesti piirkondades sama täpselt toimida — see on masinõppemudelitele üldiselt omane piirang, mitte käesoleva metoodika eripära. Kirjeldatud metoodikat (aegridade tunnuste moodustamine ja hierarhiline klassifitseerimine) saab põhimõtteliselt uute andmetega mistahes piirkonnas uuesti rakendada.

Kolmandaks olid klassid tugevalt tasakaalustamata. Männikud ja kaasikud moodustasid suurema osa andmestikust, samas kui haavikute, sanglepikute ja eriti klassi MUU näiteid oli vähe. Klassikaalude kasutamine parandas kontrollitud võrdluses tulemust, samas kui käsitsi ülevalimi mõju sõltus mudelikonfiguratsioonist ega olnud järjekindlalt positiivne. Mõlemad meetodid ei asenda siiski mitmekesiseid ja kvaliteetseid õpetusnäiteid. Klassi MUU ühe testeraldise põhjal ei olnud võimalik arvutada usaldusväärset klassipõhist tulemust.

Neljandaks kasutati ainult ühe aasta Sentinel-2 optilisi vaatlusi. Pilvisus ja kvaliteedimask vähendasid mõnes ajavahemikus kasutatavate vaatluste arvu. Mosaiikimisel kasutati iga piksli jaoks ajavahemiku viimast sobivat vaatlust, mistõttu ei pärinenud sama ajaakna kõigi eraldiste

väärtused tingimata samast kuupäevast. Alternatiivina oleks saanud kasutada ajavahemiku sobivate vaatluste keskmist väärtust või esimest sobivat vaatlust; mõlemad valikud oleksid vähendanud kuupäevade hajuvust, kuid keskmistamine oleks võinud hägustada teravaid fenoloogilisi muutusi ja esimese vaatluse valik oleks süstemaatiliselt eelistanud varasemaid kuupäevi. Puuduvad väärtused asendati treeningandmestiku mediaaniga, kuid mudelile ei lisatud tunnuseid, mis oleksid kirjeldanud vaatluse tegelikku kuupäeva või puuduvate väärtuste hulka. Seetõttu võis osa fenoloogilisest informatsioonist kaduda. Kuna aegrida ei silutud ega interpoleeritud, jäid üksikute vaatluste juhuslikud kõrvalekalded (nt jääkpilvisus, ebatäpne pilvemask) aegritta alles, mis võis mudeli tunnustesse lisada müra.

Viiendaks kasutati käsitsi koostatud liigisignatuuride kavandamisel treening-, valideerimis- ja testandmestiku ühendatud valimil tehtud uurivat analüüsi. Mudelit ennast testandmetel ei treenitud, kuid testandmestiku mustrid võisid mõjutada tunnuste valikut. Seetõttu ei saa nende tunnustega lõppmudeli testtulemust käsitleda täielikult sõltumatu üldistusvõime hinnanguna. Probleemi ulatust ei ole võimalik tagantjärele täpselt määrata, sest puudus ette fikseeritud tunnuste moodustamise reegel ja kõigi proovitud variantide täielik logi.

Kuuendaks erines pikslipõhise kaardi sisend treeningandmestikust. Eraldisepõhise mudeli treenimisel kasutati Sentinel-2 pikslite keskmisi väärtusi, kuid kaardistamisel rakendati mudelit üksikpiksli väärtustele. Kõrgustunnused arvutati piksli ümbruse liikuva akna põhjal, kuid spektraal- ja mullastikutunnuste ruumiline tugi jäi eraldisepõhisest treeningandmestikust erinevaks. Need erinevused võivad põhjustada tunnuste jaotuse muutuse treeningu ja rakendamise vahel.

Pikslipõhise kaardi ja metsaregistri takseeritud enamuspüüliigi võrdlus ei olnud sõltumatu valideerimine. Võrdluses sisaldasid ka treening- ja valideerimisandmestikku kuulunud eraldised ning eraldise kaardipõhine liik määراتi pikslite enamushääletusega, mis vähendas üksikute pikslivigade mõju. Seetõttu näitavad kaardivõrdluse kõrged vastavusnäitajad eelkõige töövoa tehnilist toimimist, mitte sõltumatu pikslipõhise puuliigikaardi täpsust.

Seitsmendaks ei häälestatud koosseisu regressioonimudelite hüperparameetreid eraldi. XGBoosti puhul modelleeriti seitsme liigi osakaale sõltumatute regressioonimudelitega, Random Forest kasutas mitmeväljundilist regressiooni; negatiivsete väärtuste nullimine ja järgnev normeerimine tagasid küll sobiva väljundvormi, kuid ei arvestanud kompositsiooni statistilist struktuuri mudeli õppimise ajal. Seetõttu tuleb koosseisu prognoosimise tulemusi käsitleda eelkõige esialgse hinnanguna.

5.6 Praktiline väärtus ja edasised uurimissuunad

Töö praktiline väärtus seisneb tervikliku andmetöötlus- ja modelleerimisvoo väljatöötamises. Metsaregistri eraldiste, Sentinel-2 aegridade, kõrgus- ja mullastikuandmete põhjal koostati enamuspuuliigi klassifitseerimise ja puistu koosseisu prognoosimise mudelid ning rakendati parimat klassifitseerimismudelit pikslipõhise puuliigikaardi loomiseks.

Tulemused näitavad, et kaugseirepõhine mudel võib täiendada metsainventuuri, aidates tuvastada eraldisi, mille registriandmed võivad vajada kontrollimist või ajakohastamist. Mudelit saaks kasutada ka puuliigikaartide koostamise, metsamuutuste seire ja välitööde suunamise ühe sisendina. Mudeli väljundit ei tule siiski käsitleda välitöödel kogutud andmete asendusena, vaid täiendava ruumilise teabekihina.

Enne meetodika kasutamist tuleks mudelit valideerida teistes metsanduslikes alamregioonides ja täiesti sõltumatutel referentsandmetel. Mudeli üldistusvõime hindamiseks oleks otstarbekas kasutada korduvat ruumilist ristvalideerimist, eri suurusega ruumiplokke ning treening- ja testalade vahelisi puhvreid. Tunnuste moodustamine ja hüperparameetrite valik tuleks teha igas korduses ainult vastava treeningjaotuse põhjal.

Pikslipõhise kaardi arendamisel tuleks ühtlustada treening- ja rakendusandmete ruumiline tugi. Sentinel-2 spektraaltunnused võiks arvutada piksli ümbruse liikuva akna keskmisena ja mullastikutunnuse piirkonna domineeriva mullatüübina. Kaardi täpsust tuleks hinnata sõltumatute välitööandmete või mudeli arendamises kasutamata eraldiste põhjal.

Väikeste klasside eristamiseks on vaja rohkem ajakohaseid ja ruumiliselt mitmekesiseid õpetusnäiteid. Klassi MUU puhul tuleks kaaluda selle eemaldamist, liikide ühendamist ökoloogiliselt põhjendatud rühmadeks või eraldi haruldaste liikide mudeli koostamist. Segapuistute jaoks tuleks arendada mudeleid, mis prognoosivad otseselt liigilist koosseisu ja selle ebakindlust, mitte ainult ühte enamuspuuliiki.

Sentinel-2 aegridadele võiks lisada Sentinel-1 radariandmeid (Udali jt, 2021) ja laserskaneerimisest tuletatud struktuuritunnuseid. Need andmeallikad võivad täiendada optilist informatsiooni pilvistel perioodidel ning aidata eristada sarnase spektraalse signatuuriga, kuid erineva võrastiku struktuuriga puistuid. Samuti võiks võrrelda otsustuspuupõhiseid meetodeid aegridade ajalist järjestust otseselt arvestavate mudelitega, kuid selline võrdlus eeldab esmalt rangemat ruumilist valideerimist ja ühtlasemat treeningandmestikku.

Kokkuvõttes näitas töö, et Sentinel-2 aegread sisaldavad Lääne-Eesti alamregiooni puuliikide eristamiseks väärtuslikku spektraalset ja fenoloogilist informatsiooni. XGBoost saavutas Random Forestist parema tulemuse nii enamuspuuliigi klassifitseerimisel kui ka puistu liigilise koosseisu prognoosimisel. Tulemuste rakendamisel tuleb siiski arvestada referentsandmete, klasside tasakaalu, ruumilise üldistatavuse ja pikslipõhise kaardi valideerimise piirangutega.

6. Kokkuvõte

Käesoleva magistritöö eesmärk oli hinnata Sentinel-2 aegridade ning kõrgus- ja mullastikuandmete kasutamise võimalusi metsaeraldise enamuspuliigi klassifitseerimisel ja puistu puuliigilise koosseisu prognoosimisel Lääne-Eesti alamregiooni näitel. Selleks koostati metsaregistri andmete põhjal 9117 puhtpuistust koosnev põhiaandmestik ja 10282 puht- ning segapuistut sisaldav laiendatud andmestik ning võrreldi Random Foresti ja XGBoosti algoritme, tunnuste valiku viise ja mudeliarhitektuure.

Enamuspuliigi klassifitseerimisel saavutas parema tulemuse XGBoost: neljaastmelise hierarhilise mudeli õigsus oli testandmestikul 0,870, makro-F1 0,692 ja Coheni kappa 0,820. XGBoost saavutas Random Forestist paremad tulemused (vastavalt 0,822, 0,625 ja 0,753) ning McNemari test kinnitas algoritmide prognooside statistiliselt olulist erinevust. Kõige paremini klassifitseeriti männikuid ja kaasikuid, kõige keerulisemaks jäi haavik, mida klassifitseeriti sageli kaasikuna. Mudeli tulemuslikkus erines märgatavalt vanuserühmade vahel: õigsus oli vähemalt 20-aastastes puistutes 0,920 ja nooremates 0,742.

Puht- ja segapuistuid sisaldaval laiendatud andmestikul oli klassifitseerimisülesanne raskem ja mudelite tulemuslikkus väiksem kui puhtpuistute põhiaandmestikul (XGBoosti õigsus 0,620 ja makro-F1 0,478, Random Forestil vastavalt 0,571 ja 0,418), kuid XGBoost jäi ka siin paremaks. Puistu koosseisu regressioonil saavutas XGBoost kõigi liikide puhul Random Forestist väiksema keskmise absoluutvea (10,70 vs. 11,82 protsendipunkti). Suurim determinatsioonikordaja saavutati männi osakaalu prognoosimisel ($R^2 = 0,59$). Puuliikide osakaalude prognoosimisel jäi siiski märkimisväärne määramatus.

Puuliikide eristamiseks vajalik informatsioon ei jaotunud aasta jooksul ühtlaselt, vaid koondus kevadesse ning hilissuvesse-sügisesse. Tunnuste arvu oli võimalik oluliselt vähendada ilma täpsust kaotamata: automaatselt valitud 50 tunnusega mudel saavutas täieliku tunnustekomplektiga peaaegu võrdse tulemuse. Tunnuste valiku põhjal näisid kõrgustunnused mullastikutunnustest informatiivsemad, kuid nende tunnuserühmade iseseisvat mõju eraldi ei testitud ning lisaandmete mõju sõltus mudelikonfiguratsioonist. Kontrollitud võrdlustes ei osutunud hierarhiline arhitektuur järjekindlalt ühetasandilisest mudelist paremaks, mistõttu ei saa lõpliku mudeli headust omistada üksnes hierarhiale — tulemus sõltus mudelikomponentide koostoimest.

Lõpliku hierarhilise XGBoosti mudeli põhjal koostati Lääne-Eesti alamregiooni kohta kümnemeetrise lahutusega pikslipõhine puuliigikaart. Kaardipõhine enamuspuuliik langes metsaregistri andmetega kokku 93,9%-l võrdlusesse kaasatud puhtpuistute eraldistest ja 72,9%-l laiendatud andmestiku eraldistest, kuid see näitab eelkõige kaardistusvoo tehnilist toimimist, mitte sõltumatut kaarditäpsust.

Töö tulemusena koostati terviklik töövoog treeningandmete valikust pikslipõhise kaardini, mis näitas Sentinel-2 aegridade väärtust puuliikide eristamisel. Tulemuste üldistamiseks tuleb metoodikat edaspidi valideerida teistes alamregioonides ja sõltumatutel andmetel, kasutades korduvat ruumilist ristvalideerimist; samuti tuleb täiustada segapuistute ja haruldaste liikide käsitlemist ning ühtlustada õpetus- ja kaardistamisandmete ruumiline tugi. Sentinel-1 radari- ja laserskaneerimisandmete lisamine võiks tulevikus veelgi parandada sarnase spektraalse signatuuriga liikide eristamist.

Summary

The aim of this master's thesis was to assess the potential of Sentinel-2 time series, canopy height data and soil information for classifying the dominant tree species of forest stands and predicting stand-level species composition, using the example of one Estonian forestry sub-region. For this purpose, a primary dataset of 9,117 pure forest stands and an extended dataset of 10,282 pure and mixed stands were compiled from the Estonian Forest Register, and the Random Forest and XGBoost algorithms, feature-selection strategies and model architectures were compared.

XGBoost achieved the better result in dominant species classification: the four-stage hierarchical model reached a test-set accuracy of 0.870, macro-F1 of 0.692 and Cohen's kappa of 0.820. XGBoost outperformed Random Forest (0.822, 0.625 and 0.753, respectively), and a McNemar test confirmed that the difference between the two algorithms' predictions was statistically significant. Pine and birch were classified most accurately, while aspen remained the most difficult species, often confused with birch. Model performance differed markedly between stand-age groups: accuracy was 0.920 in stands at least 20 years old, compared with 0.742 in younger stands.

On the extended dataset containing both pure and mixed stands, the classification task was harder and model performance lower than on the pure-stand dataset (XGBoost accuracy 0.620, macro-F1 0.478; Random Forest 0.571 and 0.418, respectively), though XGBoost remained the better model. For predicting stand species composition, XGBoost achieved a lower mean absolute error than Random Forest for every species (10.70 vs. 11.82 percentage points). The highest coefficient of determination was reached for pine's share ($R^2 = 0.59$). Predicting species proportions nevertheless remained subject to considerable uncertainty.

Information relevant to species discrimination was not distributed evenly across the year, but concentrated in spring and late summer/autumn. The number of features could be substantially reduced without losing accuracy: a model using only the 50 most important automatically selected features performed nearly as well as one using the complete feature set. Height features proved more informative than soil features, though the effect of the additional data depended on the model configuration. In controlled comparisons, the hierarchical architecture did not consistently outperform a single-stage model, so the final model's performance cannot be attributed to the hierarchy alone — it depended on the interaction of several model components.

The final hierarchical XGBoost model was used to produce a 10-metre resolution pixel-based tree species map of the Western Estonian sub-region. The map's dominant species agreed with Forest Register data for 93.9% of the pure-stand parcels included in the comparison and 72.9% of parcels in the extended dataset; this mainly confirms the technical functioning of the mapping workflow rather than providing an independent accuracy estimate.

This thesis produced a complete workflow from reference-data selection to a pixel-based species map, demonstrating the value of Sentinel-2 time series for tree species discrimination. Generalizing the results to all of Estonia will require validating the methodology in other sub-regions on fully independent data, using repeated spatial cross-validation, improving the treatment of mixed stands and rare species, and harmonizing the spatial support of training and mapping features. Combining Sentinel-2 time series with Sentinel-1 radar and airborne laser scanning data could further improve the discrimination of spectrally similar species.

Viidatud kirjandus

- Anthropic. (2026). *Claude* [Large language model]. <https://www.anthropic.com/claude>
- Burkov, A. (2019). *The hundred-page machine learning book*. Andriy Burkov.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46. <https://doi.org/10.1177/001316446002000104>
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.
- Copernicus Data Space Ecosystem. (2025, January 8). *Copernicus Sentinel-2 mission update: Transfer of duty from Sentinel-2A to Sentinel-2C on 21 January 2025*. <https://dataspace.copernicus.eu/news/2025-1-8-copernicus-sentinel-2-mission-update-transfer-duty-sentinel-2a-sentinel-2c-21-january>
- Daryaei, A., Lechner, M., Iglseider, A., Waser, L. T., & Immitzer, M. (2025). Sentinel-2 vs. PlanetScope: Comparison and combination for tree species classification in two Central European forest ecosystems. *Remote Sensing Applications: Society and Environment*, 38, 101617. <https://doi.org/10.1016/j.rsase.2025.101617>
- European Parliament & Council of the European Union. (2023). Regulation (EU) 2023/839 of the European Parliament and of the Council of 19 April 2023 amending Regulation (EU) 2018/841 as regards the scope, simplifying the reporting and compliance rules, and setting out the targets of the Member States for 2030, and Regulation (EU) 2018/1999 as regards improvement in monitoring, reporting, tracking of progress and review. *Official Journal of the European Union*, L 107, 1–28. <https://eur-lex.europa.eu/eli/reg/2023/839/oj/eng>
- European Space Agency. (2015). *Sentinel-2 user handbook* (Issue 1, Rev. 2). https://sentinels.copernicus.eu/documents/247904/685211/Sentinel-2_User_Handbook
- Grabska, E., Hostert, P., Pflugmacher, D., & Ostapowicz, K. (2019). Forest stand species mapping using the Sentinel-2 time series. *Remote Sensing*, 11(10), 1197. <https://doi.org/10.3390/rs11101197>
- Gupta, N., & Wen, J. L. (2023). Evaluating machine learning algorithms to classify forest tree species through satellite imagery. *Journal of Emerging Investigators*, 6, 1–10. <https://doi.org/10.59720/22-153>
- Hemmerling, J., Pflugmacher, D., & Hostert, P. (2021). Mapping temperate forest tree species using dense Sentinel-2 time series. *Remote Sensing of Environment*, 267, 112743. <https://doi.org/10.1016/j.rse.2021.112743>
- Immitzer, M., Neuwirth, M., Böck, S., Brenner, H., Vuolo, F., & Atzberger, C. (2019). Optimal input features for tree species classification in Central Europe based on multi-temporal Sentinel-2 data. *Remote Sensing*, 11(22), 2599. <https://doi.org/10.3390/rs11222599>

Kaha, M. (2017). *Puistute liigilise koosseisu hindamine multispektraalsete satelliitpiltide põhjal* [Magistritöö, Eesti Maaülikool]. <http://hdl.handle.net/10492/3382>

Karasiak, N., Dejoux, J.-F., Monteil, C., & Sheeren, D. (2022). Spatial dependence between training and test sets: Another pitfall of classification accuracy assessment in remote sensing. *Machine Learning*, 111(7), 2715–2740. <https://doi.org/10.1007/s10994-021-05972-1>

Keskkonnaagentuur. (2024). *Eesti üldpindala jaotus maakategooriate järgi*. <https://tableau.envir.ee/views/SMI/1Maakategooriad>

Keskkonnaagentuur. (2025). *Eesti metsade kõrguskaart*. Keskkonnaportaal. <https://keskkonnaportaal.ee/et/eesi-metsade-korguskaart>

Keskkonnaagentuur. (2026). *Metsamaski meetodika loomine*. Keskkonnaportaal. Vaadatud 11. augustil 2026, aadressilt <https://keskkonnaportaal.ee/et/metsamaski-meetodika-loomine>

Klehr, D., Stoffels, J., Hill, A., Pham, V.-D., van der Linden, S., & Frantz, D. (2025). Mapping tree species fractions in temperate mixed forests using Sentinel-2 time series and synthetically mixed training data. *Remote Sensing of Environment*, 323, 114740. <https://doi.org/10.1016/j.rse.2025.114740>

Kliimaministeerium. (2026). *Metsandus*. <https://kliimaministeerium.ee/elurikkus-keskkonnakaitse/metsandus>

Lang, M., Kaha, M., Laarmann, D., & Sims, A. (2018). Construction of tree species composition map of Estonia using multispectral satellite images, soil map and a random forest algorithm. *Forestry Studies | Metsanduslikud Uurimused*, 68, 5–24. <https://doi.org/10.2478/fsmu-2018-0001>

Lechner, M., Dostálová, A., Hollaus, M., Atzberger, C., & Immitzer, M. (2022). Combination of Sentinel-1 and Sentinel-2 data for tree species classification in a Central European biosphere reserve. *Remote Sensing*, 14(11), 2687. <https://doi.org/10.3390/rs14112687>

Lõhmus, E. (2004). *Eesti metsakasvukohatüübid* (2. tr). Eesti Loodusfoto.

Maa-amet. (2001). *Mullastiku kaart*. Geoportaal. Vaadatud 1. augustil 2026, aadressilt <https://geoportaal.maaamet.ee/est/ruumiandmed/mullastiku-kaart-p33.html>

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2), 153–157. <https://doi.org/10.1007/BF02295996>

Metsa korraldamise juhend. (2024). *Riigi Teataja* (RT I, 31.05.2024, 11). <https://www.riigiteataja.ee/akt/131052024011>

Müller, A. C., & Guido, S. (2017). *Introduction to machine learning with Python: A guide for data scientists*. O'Reilly Media.

Sentinel Hub. (n.d.-a). *Evalsript V3*. Vaadatud 1. augustil 2026, aadressilt <https://docs.sentinel-hub.com/api/latest/evalscript/v3/>

Sentinel Hub. (n.d.-b). *Processing API*. Vaadatud 12. augustil 2026, aadressilt <https://docs.sentinel-hub.com/api/latest/api/process/>

Sentinel Hub. (n.d.-c). *Statistical API*. Vaadatud 1. augustil 2026, aadressilt <https://docs.sentinel-hub.com/api/latest/api/statistical/>

Shanin, V., Komarov, A., & Mäkipää, R. (2014). Tree species composition affects productivity and carbon dynamics of different site types in boreal forests. *European Journal of Forest Research*, 133(2), 273–286. <https://doi.org/10.1007/s10342-013-0759-1>

Sügis, E., Tampuu, A., Aljanaki, A., Fišel, M., & Kull, M. (2024). *Praktiline andmeteadus*. Tartu Ülikooli arvutiteaduse instituut.

Udali, A., Lingua, E., & Persson, H. J. (2021). Assessing forest type and tree species classification using Sentinel-1 C-band SAR data in southern Sweden. *Remote Sensing*, 13(16), 3237. <https://doi.org/10.3390/rs13163237>

Wenger, R., Bressant, C., Roettele, L., Forestier, G., & Puissant, A. (2024). Improving urban tree species classification with high resolution satellite imagery and machine learning. In *IGARSS 2024—2024 IEEE International Geoscience and Remote Sensing Symposium* (pp. 4679–4682). IEEE. <https://doi.org/10.1109/IGARSS53475.2024.10642787>

White, J. C., Coops, N. C., Wulder, M. A., Vastaranta, M., Hilker, T., & Tompalski, P. (2016). Remote sensing technologies for enhancing forest inventories: A review. *Canadian Journal of Remote Sensing*, 42(5), 619–641. <https://doi.org/10.1080/07038992.2016.1207484>

Lisad

Lisa 1. Satelliidipõhiste puuliikide klassifitseerimise ja koosseisu prognoosimise uuringute võrdlus

Autor(id), aasta	Uurimisala	Satelliit/andur	Lisaandmed	Meetod/lähenemine	ML-mudel	Ülesande tüüp	Liikide arv	Täpsus
Kaha, 2017 (EMÜ magistritöö, juh. M. Lang)	Järvelja Õppe- ja Katsemetskond, Eesti (10 396 ha)	Landsat-8 OLI, Sentinel-2 MSI (2015), Landsat-7 ETM+ (2000)	Takseerandmed (2001, 2011), CLC2000, ortofotod (valideerimiseks)	Puhtpuistute õpetusaladel aegridade spektraalne kNN- klassifikatsioon (IDRISI Taiga)	k-lähima naabri (kNN)	Klassifikat- sioon	5 (+ vanusekla ssid+ lage ala)	S2: OA 76,9%, $\kappa \approx$ 0,70; Landsat-8: OA 75,5%, $\kappa \approx$ 0,65; Landsat-7: OA 65,7%, $\kappa \approx$ 0,58. Haavik läbivalt nõrk (κ 0,06– 0,19).
Lang, Kaha, Laarmann, Sims, 2018	Eesti, terve riik (42 755 km ²)	Landsat-8 OLI + Sentinel-2 MSI (2015– 2016, 85 pilti/paari)	1:10000 mullakaart, FIDB takseerandmed	Pikslipõhine RF (25 m), klassitõenäosused tõlgendatud koosseisu osakaaluna, alampiirkondade kaupa	Random Forest	Klassifikat- sioon (+ tuletatud koosseis)	7 + „muu“	Enamusliik: OA 75,5%, κ 0,66; $\geq$ 20- aastastel OA 78,4%, κ 0,69; okaspuude osak harvesterandmetel R^2 = 0,75; enamusliikide pind mk tasemel R^2 = 0,98 riigimetsas ja 0,93 erametsas.
Grabska jt, 2019	Poola, Karpaadid (Baligródi)	Sentinel-2 aegrida (18 kuupäeva, 2018)	—	MDA/MDG tunnuste valik + fenoloogiline analüüs, parim 5-	Random Forest	Klassifikat- sioon	9	Parim OA 92,4%; üksikpildiga 84,9– 87,4%

Autor(id), aasta	Uurimisala	Satelliit/andur	Lisaandmed	Meetod/lähenemine	ML-mudel	Ülesande tüüp	Liikide arv	Täpsus
	metskond, 240 km ²)			kuupäevaline kombinatsioon				
Immitzer jt, 2019	Austria, Wienerwaldi biosfäärikaitseala	Sentinel-2 multitemporaalne (18 kuupäeva)	—	Kaheastmeline: maakattestrat → eraldi klassifikatsioon okas-/lehtpuudele, MDA tunnuste valik, indeksid	Random Forest	Klassifikatsioon	12 (5 okas- + 7 lehtpuud)	Kombineeritud mudel OA 89,9%, Kappa 0,885; stratifitseerituna: lehtpuud 85,7% / okaspuud 95,3%
Hemmerling jt, 2021	Saksamaa, Brandenburg (~30 000 km ²)	Sentinel-2 tihe aegrida (RBF-interpoleeritud, 5-päevane)	Kliima, topograafia, kasvukoha/mulla boniteet, tekstuur	4 tunnusekomplekti võrdlus (spekter / keskkond / mõlemad / +tekstuur)	Random Forest (500 puud)	Klassifikatsioon	17	OA 96,0% (spekter); ainult keskkond 69,4%; lisatunnused parandasid vaid marginaalselt
Lechner jt, 2022	Austria, Wienerwaldi biosfäärikaitseala (105 000 ha)	Sentinel-1 (250 stseeni) + Sentinel-2 (14 stseeni), 2018	DEM (radiomeetriliseks korrigeerimiseks), S1 fenoloogilised/harmonilised parameetrid	9 katsejuhtu (S1/S2 eraldi ja kombineerituna, mono- vs multitemporaalne), indeksid	Random Forest (1000 puud)	Klassifikatsioon	12	S1 üksi OA 55,7% $\kappa=0,469$; S2 üksi 83,2% $\kappa=0,806$; S1+S2 83,7% $\kappa=0,811$ (+0,5pp)
Gupta ja Wen, 2023 (JEI)	USA, Lake Tahoe / El Dorado	Landsat-8 OLI (ainult RGB kanalid)	—	Pikslipõhine, 4 algoritmi võrdlus,	RF, kNN, Gradient	Klassifikatsioon	10	RF sama piirkond 95,4%/94,7%, eri piirkond

Autor(id), aasta	Uurimisala	Satelliit/andur	Lisaandmed	Meetod/lähenemine	ML-mudel	Ülesande tüüp	Liikide arv	Täpsus
	National Forest, California			treening/valideerimine sama vs eri piirkond	Boosting, LDA (RF parim)			73,5%/59,3%, keskmine 80,7%
Wenger jt, 2024 (IGARSS)	Prantsusmaa, Strasbourgi linnaala (linnapuud)	Pléiades (0,5 m) + PlanetScope (3,1 m) + Sentinel-2 (10–20 m), 2022	DSM (Pléiades tri-stereo põhjal), puude andmebaas	Objektipõhine (teoreetiline võrapuhver vs watershed-segmenteerimine), 8 anduri/indeksi kombinatsiooni	Random Forest (1000 puud)	Klassifikatsioon	10	Parim: accuracy 0,73, kaalutud F1 0,72; parim liik F1 0,90
Daryaei jt, 2025	Austria, 2 metsaökosüsteemi (NPDA 9800 ha, Wienerwald BRWW 105 000 ha)	Sentinel-2 vs PlanetScope, eraldi ja kombineerituna	—	Mono- vs multitemporaalne võrdlus, MDA tunnuste valik	Random Forest	Klassifikatsioon	12	OA 78,3%/83,3% (ainult S2); kombineerituna 80,1%/84,6%
Klehr jt, 2025	Saksamaa, Rheinland-Pfalz (8080 km ² mets)	Sentinel-2 aastane tihe aegrida 2022, 10-päevane)	Metsakorralduse andmed, NFI, ortofotod, LiDAR-põhine kõrgusmudel (valideerimiseks)	Sünteesiliselt segatud treeningandmetega regressioonipõhine „unmixing“ (piksli-sisene osakaalu prognoos)	Tehisnärvivõrk	Koosseisu regressioon	9 + „muu“ klass	R ² =0,91; tase 2 (liik): R ² 0,41–0,92, MAE 2,76–16,05%

Lisa 2. Peamiste katsete kokkuvõte ja hüperparameetrite otsingu tulemused

Lisa 2.1. Peamiste katsete kokkuvõte.

Tabel L2.1. Käesolevas töös viidatud peamiste katsete kokkuvõte.

EXP-kood	Algoritm	Andmestik	Kirjeldus	Peatükk
EXP000	Random Forest	Puhtpuistud (9776, ilma lageraiefiltrita)	Üheastmeline baasmudel	ptk 4.1
EXP032	Random Forest	Puhtpuistud (9117)	Lõplik neljaastmeline hierarhiline mudel (ptk 3.6 arhitektuur)	ptk 4.3, 5.1
EXP038	XGBoost	Puhtpuistud (9117)	Neljaastmeline hierarhiline XGBoost; lõplikuks valitud klassifitseerimismudel	ptk 4.3, 5.1
EXP041	XGBoost	Puhtpuistud (9117)	Hüperparameetrite võrguotsing (10 konfiguratsiooni) EXP038 arhitektuuril	Lisa 2.2
EXP042	Random Forest	Puhtpuistud (9117)	Hüperparameetrite võrguotsing (9 konfiguratsiooni) EXP032 arhitektuuril	Lisa 2.2
EXP048	Random Forest	Puhtpuistud + segapuistud (10282)	EXP032 arhitektuur laiendatud andmestikul	ptk 4.5.1
EXP049	XGBoost	Puhtpuistud + segapuistud (10282)	EXP038 arhitektuur laiendatud andmestikul	ptk 4.5.1
EXP050	Random Forest	Puhtpuistud + segapuistud (10282)	Mitmeväljundiline puuliigilise koosseisu (osakaalude) regressioon	ptk 4.5.2
EXP076	XGBoost	Puhtpuistud + segapuistud (10282)	Mitmeväljundiline koosseisu regressioon (MultiOutputRegressor)	ptk 4.5.2

Lisa 2.2. Hüperparameetrite võrguotsingu tulemused.

Ptk 3.5.1 kirjeldatud süstemaatiline võrguotsing tehti pärast lõpliku hierarhilise arhitektuuri ja selle lähtekonfiguratsiooni (ptk 3.6) fikseerimist, tundlikkusanalüüsina — mitte konfiguratsiooni valiku vahendina. Otsing võrdles valideerimisandmestikul mitut hüperparameetrite kombinatsiooni mõlema algoritmi lõplikul hierarhilisel arhitektuuril. Allolevad tabelid (L2.2, L2.3) esitavad kõigi katsetatud konfiguratsioonide tulemused, järjestatuna valideerimisandmestiku Macro F1 väärtuse järgi. Lisaks on esitatud sama liiki hüperparameetrite otsing ka ptk 4.2 kontrollitud komponentide eemaldamise uuringu lihtsama, ühetasandilise ja Top-50 tunnustega töövoos kontekstis (Tabel L2.4, L2.5, vastavad Tabel 4.3 sammudele 7 ja 5) — need kaks otsingut tehti erinevas mudelikontekstis ega ole omavahel otseselt võrreldavad, kuid annavad koos täielikuma pildi tulemuse tundlikkusest hüperparameetrite valikule.

Tabel L2.2. EXP041 (XGBoost) hüperparameetrite võrguotsingu tulemused valideerimisandmestikul (10 konfiguratsiooni). Valitud lähtekonfiguratsioon (400 puud, sügavus 6, õpisamm 0,1, ilma alamvalimita) saavutas Macro F1 0,689 — peaaegu võrdselt parimana leitud konfiguratsiooniga (0,699), mis viitab tulemuse väikesele tundlikkusele hüperparameetrite valikule selles vahemikus.

n_esti- mators	max_depth	learning_rate	subsample	colsample_bytree	Val Macro F1	Val HB F1
500	5	0,08	-	-	0,699	0,690
700	6	0,10	-	-	0,694	0,627
600	6	0,05	0,8	0,8	0,693	0,634
400	8	0,10	0,9	0,9	0,691	0,651
400	6	0,10	-	-	0,689	0,642
800	4	0,05	-	-	0,688	0,608
400	10	0,05	0,7	0,7	0,688	0,615
300	6	0,15	0,8	1,0	0,685	0,593
200	9	0,10	-	-	0,681	0,597
1000	4	0,03	-	-	0,680	0,608

Tabel L2.3. EXP042 (Random Forest) hüperparameetrite võrguotsingu tulemused valideerimisandmestikul (9 konfiguratsiooni). Valitud lähtekonfiguratsioon (400 puud, minimaalne lehesuurus 2, tasakaalustatud klassikaalud, piiramata sügavus) jääb parima leitud konfiguratsiooni (Macro F1 0,657) lähedale (0,654).

n_estimators	max_depth	min_samples_leaf	max_features	class_weight	Val Macro F1	Val HB F1
1000	-	4	sqrt	balanced_subsample	0,657	0,629
400	-	2	Sqrt	balanced	0,654	0,588
400	-	1	sqrt	balanced	0,651	0,567
700	-	1	sqrt	balanced_subsample	0,648	0,531
700	-	2	sqrt	balanced	0,648	0,545
700	40	1	log2	balanced	0,646	0,523
1000	-	2	sqrt	balanced_subsample	0,644	0,531
1000	60	1	0,3	balanced_subsample	0,632	0,500
700	30	2	0,5	balanced	0,631	0,526

Tabel L2.4. XGBoost hüperparameetrite võrguotsingu tulemused ptk 4.2 kontrollitud komponentide eemaldamise uuringu ühetasandilisel, Top-50 tunnustega *pipeline*'il (valideerimisandmestik, 10 konfiguratsiooni, vastab Tabel 4.3 sammule 7). Parim konfiguratsioon (500 puud, sügavus 5, õpisamm 0,08, *min_child_weight*=5, *gamma*=0,1) saavutas Macro F1 0,707.

n_estimators	max_depth	learning_rate	Val Accuracy	Val Macro F1	Val Kappa
500	5	0,08	0,874	0,707	0,824
600	6	0,05	0,871	0,697	0,819
700	6	0,10	0,874	0,697	0,822
400	6	0,10	0,872	0,696	0,820
400	8	0,10	0,875	0,695	0,825
300	6	0,15	0,871	0,691	0,819
800	4	0,05	0,867	0,688	0,814
400	10	0,05	0,868	0,686	0,814
1000	4	0,03	0,866	0,682	0,812
200	9	0,10	0,861	0,681	0,805

Tabel L2.5. Random Forest hüperparameetrite võrguotsingu tulemused ptk 4.2 kontrollitud komponentide eemaldamise uuringu ühetasandilisel, Top-50 tunnustega *pipeline*'il (valideerimisandmestik, 9 konfiguratsiooni, vastab Tabel 4.3 sammule 5). Parim konfiguratsioon (700 puud, *min_samples_leaf*=2, *max_features*=sqrt, *class_weight*=balanced) saavutas Macro F1 0,665.

n_estimators	max_depth	min_samples_leaf	max_features	class_weight	Val Accuracy	Val Macro F1	Val Kappa
700	—	2	sqrt	balanced	0,839	0,665	0,778
400	—	2	sqrt	balanced	0,839	0,660	0,778
700	40	1	log2	balanced	0,836	0,655	0,772
700	30	2	0,5	balanced	0,836	0,651	0,773
1000	—	4	sqrt	balanced_subsample	0,838	0,646	0,772

n_estimators	max_depth	min_samples_leaf	max_features	class_weight	Val Accuracy	Val Macro F1	Val Kappa
1000	60	1	0,3	balanced_subsample	0,844	0,641	0,777
400	—	1	sqrt	balanced	0,832	0,639	0,766
1000	—	2	sqrt	balanced_subsample	0,840	0,636	0,773
700	—	1	sqrt	balanced_subsample	0,833	0,623	0,761

Lisa 3. Töös kasutatud vegetatsiooniindeksite valemid

Tabel L3.1 Vegetatsiooniindeksite valemid

Indeks	Nimetus	Valem (Sentinel-2 kanalid)
NDVI	Normalized Difference Vegetation Index	$(B08 - B04) / (B08 + B04)$
NDRE	Normalized Difference Red Edge Index	$(B08 - B05) / (B08 + B05)$
NDMI	Normalized Difference Moisture Index	$(B08 - B11) / (B08 + B11)$
NBR	Normalized Burn Ratio	$(B08 - B12) / (B08 + B12)$
EVI	Enhanced Vegetation Index	$2,5 \times (B08 - B04) / (B08 + 6 \times B04 - 7,5 \times B02 + 1)$
CIRE	Chlorophyll Index Red Edge	$(B08 / B05) - 1$

Valemites kasutatud B02, B04, B05, B08, B11 ja B12 tähistavad Sentinel-2 Level-2A atmosfäärikorrektsooniga pinnapegeldustegureid (BOA reflectance).

Lihtlitsents

Lihtlitsents lõputöö reprodutseerimiseks ja üldsusele kättesaadavaks tegemiseks

Mina, Liis Lille

1. annan Tartu Ülikoolile tasuta loa (lihtlitsentsi) minu loodud teose „Puuliikide tuvastamine Eesti metsades Sentinel-2 satelliidipiltide aegridade põhjal“, mille juhendaja on Mait Lang,

reprodutseerimiseks eesmärgiga seda säilitada, sealhulgas lisada Tartu Ülikooli digitaalarhiivi kuni autoriõiguse kehtivuse lõppemiseni;
2. annan Tartu Ülikoolile loa teha punktis 1 nimetatud teos üldsusele kättesaadavaks Tartu Ülikooli veebikeskkonna, sealhulgas digitaalarhiivi kaudu Creative Commons'i litsentsiga CC BY NC ND 4.0, mis lubab autorile viidates teost reprodutseerida, levitada ja üldsusele suunata ning keelab luua tuletatud teost ja kasutada teost ärieesmärgil, kuni autoriõiguse kehtivuse lõppemiseni;
3. olen teadlik, et punktides 1 ja 2 nimetatud õigused jäävad alles ka autorile;
4. kinnitan, et lihtlitsentsi andmisega ei riku ma teiste isikute intellektuaalomandi ega isikuandmete kaitse õigusaktidest tulenevaid õigusi.

Liis Lille
11.08.2026